



(21) 申请号 202410996650.X

G06F 16/335 (2019.01)

(22) 申请日 2024.07.24

(56) 对比文件

(65) 同一申请的已公布的文献号

CN 114706948 A, 2022.07.05

申请公布号 CN 118939811 A

CN 118093604 A, 2024.05.28

(43) 申请公布日 2024.11.12

审查员 陈琪

(73) 专利权人 广西警察学院

地址 530028 广西壮族自治区南宁市青秀
区长湖路6号(72) 发明人 秦振凯 陈悦 朱雨燕 李玲莹
莫星宇 叶李霞 魏文婧 林子倩(74) 专利代理机构 江苏昌禾律师事务所 32837
专利代理师 潘天志

(51) Int. Cl.

G06F 16/36 (2019.01)

G06F 16/953 (2019.01)


权利要求书6页 说明书15页 附图2页

(54) 发明名称

一种基于新闻来源可信度的舆情知识图谱
过滤方法

(57) 摘要

本发明公开了一种基于新闻来源可信度的舆情知识图谱过滤方法,包括S1、生成初始新闻数据集;S2、通过建立可信度评估模型;S3、保留高可信度的新闻数据;S4、使用自然语言处理技术,对保留的新闻数据进行文本预处理;S5、生成初步的实体和关系数据;S6、基于初步的实体和关系数据,构建初始舆情知识图谱;S7、动态更新舆情知识图谱;S8、识别出对特定事件或话题的舆情态度和趋势;S9、优化知识图谱的数据质量;S10、基于优化后的舆情知识图谱进行舆情分析,生成舆情报告。本发明有效解决了现有技术中的缺陷和不足,实现了高质量、高时效性的舆情分析,为用户提供了可靠的决策支持和管理参考。



1.一种基于新闻来源可信度的舆情知识图谱过滤方法,其特征在于,包括如下步骤:

S1、自动从各种新闻媒体和在线平台收集新闻报道,生成初始新闻数据集;

S2、通过建立可信度评估模型,对初始新闻数据集中各新闻来源进行可信度分析和评价;

S3、根据可信度分析和评价结果,过滤掉低可信度的新闻来源,仅保留高可信度的新闻数据;

S4、使用自然语言处理技术,对保留的新闻数据进行文本预处理,包括分词、去停用词和句法分析;

S5、对预处理后的新闻文本进行命名实体识别和关系抽取,生成初步的实体和关系数据;

S6、基于初步的实体和关系数据,构建初始舆情知识图谱,将新闻中的实体及其关系表示为结构化数据;

S7、随着新的新闻数据的出现,动态更新舆情知识图谱;

S8、使用情感分析技术,对舆情知识图谱中的新闻内容进行情感倾向评估,识别出对特定事件或话题的舆情态度和趋势;

S9、基于可信度评价和情感分析结果,对舆情知识图谱进行进一步过滤,优化知识图谱的数据质量;

S10、基于优化后的舆情知识图谱进行舆情分析,生成舆情报告;

所述S1具体包括:

S11、从各种新闻媒体和在线平台收集新闻报道数据,其中新闻媒体包括但不限于新闻网站、社交媒体平台和博客;

S12、将收集到的新闻报道数据进行格式统一化处理,生成初始新闻数据集 D_0 ;

S13、定义初始新闻数据集:

$$D_0 = \{d_0^1, d_0^2, \dots, d_0^n\};$$

其中, d_0^i 表示第*i*条新闻报道数据;

S14、为每条新闻报道数据 d_0^i 添加来源标签 S_0^i :

$$D_1 = \{(d_0^1, S_0^1), (d_0^2, S_0^2), \dots, (d_0^n, S_0^n)\};$$

其中, S_0^i 表示第*i*条新闻的来源;

S15、对新闻数据集 D_1 进行时间戳标记,标记形式为 T_0^i :

$$D_2 = \{(d_0^1, S_0^1, T_0^1), (d_0^2, S_0^2, T_0^2), \dots, (d_0^n, S_0^n, T_0^n)\};$$

其中, T_0^i 表示第*i*条新闻的发布时间;

所述S2具体包括:

S21、为每个新闻来源 S_0^i 定义一个可信度评分模型 M ;

S22、通过可信度评分模型 M 对初始新闻数据集 D_2 中的每个新闻来源进行历史数据分析,计算其可信度评分 C_0^i ;

S23、可信度评分 C_0^i 的计算公式为:

$$C_0^i = \alpha \cdot f(H_0^i) + \beta \cdot g(Q_0^i) + \gamma \cdot h(R_0^i);$$

其中, H_0^i 表示新闻来源 S_0^i 的历史可靠性, Q_0^i 表示新闻报道质量, R_0^i 表示新闻来源的专家评价, α 、 β 、 γ 为权重系数;

S24、对每个新闻来源 S_0^i 进行多维度数据收集, 包括新闻发布频率 F_0^i 、历史准确性 A_0^i 、用户反馈 U_0^i :

$$H_0^i = \frac{1}{N} \sum_{j=1}^N \left(\frac{1}{1 + e^{-(P_0^i(j) - \mu_p)}} \right);$$

其中, $P_0^i(j)$ 表示新闻来源 S_0^i 在第 j 条新闻中的准确性评分, μ_p 为准确性评分的平均值, N 为新闻总数;

$$Q_0^i = \sqrt{\frac{1}{M} \sum_{k=1}^M (Q_{0k}^i - \bar{Q}_0^i)^2};$$

其中, Q_{0k}^i 表示新闻 k 的质量评分, $\bar{Q}_0^i$ 为新闻来源 S_0^i 的平均质量评分, M 为质量评分总数;

$$R_0^i = \sum_{l=1}^L E_0^i(l) \cdot w_l;$$

其中, $E_0^i(l)$ 表示专家 l 对新闻来源 S_0^i 的评分, w_l 为专家 l 的权重, L 为参与评分的专家总数;

S25、将多维度数据输入可信度评分模型 M , 计算综合可信度评分 C_0^i , 并进行归一化处理;

S26、根据可信度评分集 C , 对初始新闻数据集 D_2 进行筛选, 仅保留可信度评分 C_0^i 高于预设阈值 T_c 的新闻数据, 生成可信新闻数据集 D_3 :

$$D_3 = \{d_0^i \in D_2 | C_0^i > T_c\}.$$

2. 根据权利要求1所述的一种基于新闻来源可信度的舆情知识图谱过滤方法, 其特征在于, 所述S4具体包括:

S41、对可信新闻数据集 D_3 中的每条新闻数据 d_0^i 进行分词处理, 生成词序列 W_0^i ;

S42、对词序列 W_0^i 进行去停用词处理, 移除常见但无意义的词语, 生成净化后的词序列 W_1^i ;

S43、对净化后的词序列 W_1^i 进行句法分析, 生成句法结构 S_1^i , 包括词性标注和依存关系分析:

$$S_1^i = \left\{ \left(w_1^i(k), \text{pos}_1^i(k), \text{dep}_1^i(k) \right) | k = 1, 2, \dots, n \right\};$$

其中, $\text{pos}_1^i(k)$ 表示词 $w_1^i(k)$ 的词性, $\text{dep}_1^i(k)$ 表示词 $w_1^i(k)$ 与其他词的依存关系;

S44、将经过分词、去停用词和句法分析处理后的新闻数据 S_1^i 作为输入, 生成预处理后的新闻数据集 D_4 。

3. 根据权利要求2所述的一种基于新闻来源可信度的舆情知识图谱过滤方法, 其特征在于, 所述S5具体包括:

S51、对预处理后的新闻数据集 D_4 中的每条新闻数据 S_1^i 使用增强型预训练语言模型BERT进行深度语义理解, 生成包含上下文信息的嵌入向量 V_1^i :

$$V_1^i = \{v_1^i(1), v_1^i(2), \dots, v_1^i(n)\};$$

其中, $v_1^i(j)$ 表示新闻数据 S_1^i 中第 j 个词的上下文嵌入向量, n 为词的总数, 具体生成嵌入向量的公式如下:

$$v_1^i(j) = \text{BERT}(W_1^i(j), \{W_1^i(1), W_1^i(2), \dots, W_1^i(n)\});$$

其中, BERT 表示 BERT 模型, $W_1^i(j)$ 表示第 j 个词及其上下文词语;

S52、利用基于变换器的命名实体识别模型 SpanBERT 对嵌入向量 $v_1^i(j)$ 进行实体识别, 生成包含实体边界和类别的集合 E_2^i :

$$E_2^i = \{(b_1, e_1, c_1), (b_2, e_2, c_2), \dots, (b_p, e_p, c_p)\};$$

其中, b_j 和 e_j 分别表示第 j 个实体的起始和结束位置, c_j 表示实体类别, p 为识别出的实体总数, 具体识别过程如下:

$$P(e_j | v_1^i) = \frac{\exp(\text{SpanBERT}(v_1^i) \cdot W_{c_j} + b_{c_j})}{\sum_c \exp(\text{SpanBERT}(v_1^i) \cdot W_c + b_c)};$$

其中, $P(e_j | v_1^i)$ 表示实体 e_j 的概率, SpanBERT 表示 SpanBERT 模型, W_{c_j} 和 b_{c_j} 分别表示类别 c_j 的权重和偏置;

S53、利用基于图神经网络的关系抽取模型, 对实体集合 E_2^i 及其上下文嵌入向量进行关系推断, 生成关系集合 R_2^i :

$$R_2^i = \{(e_2^i(a), e_2^i(b), t_2^i(k)) | a, b \in \{1, 2, \dots, p\}\};$$

其中, $t_2^i(k)$ 表示实体对 $(e_2^i(a), e_2^i(b))$ 的关系类型, 包括合作、冲突、隶属, 关系推断的具体公式如下:

$$h_{e_2^i(a), e_2^i(b)}^{(l+1)} = \sigma(W^{(l)} \cdot \sum_{e_2^i(m) \in N(e_2^i(a), e_2^i(b))} \alpha_{am}^{(l)} h_{e_2^i(m)}^{(l)});$$

$$\alpha_{am}^{(l)} = \frac{\exp(\text{LeakyReLU}(a^T [W^{(l)} h_{e_2^i(a)}^{(l)} \| W^{(l)} h_{e_2^i(m)}^{(l)}])))}{\sum_{e_2^i(n) \in N(e_2^i(a))} \exp(\text{LeakyReLU}(a^T [W^{(l)} h_{e_2^i(a)}^{(l)} \| W^{(l)} h_{e_2^i(n)}^{(l)}])));$$

其中, $h_{e_2^i(a), e_2^i(b)}^{(l+1)}$ 表示第 $l+1$ 层中实体 $e_2^i(a), e_2^i(b)$ 的嵌入向量, $N(e_2^i(a), e_2^i(b))$ 表示实体对的邻居集合, $W^{(l)}$ 表示第 l 层的权重矩阵, $\alpha_{am}^{(l)}$ 表示注意力系数, a 表示注意力机制的参数向量, $\|$ 表示向量连接操作;

S54、使用自监督学习方法对实体和关系数据进行验证和修正, 确保其准确性和一致性, 生成修正后的实体和关系数据 D_6 :

$$D_6 = \{(E_2^i, R_2^i) | i = 1, 2, \dots, n\};$$

验证和修正的具体过程如下:

$$\mathcal{L}_{\text{self}} = - \sum_{(e_2^i(a), e_2^i(b)) \in R_2^i} \log P(t_2^i(k) | e_2^i(a), e_2^i(b)) + \lambda \sum_{i=1}^n \|\Theta\|^2;$$

其中, $\mathcal{L}_{\text{self}}$ 表示自监督学习的损失函数, $P(t_2^i(k)|e_2^i(a), e_2^i(b))$ 表示给定实体对 $(e_2^i(a), e_2^i(b))$ 的关系类型 $t_2^i(k)$ 的概率, λ 为正则化参数, Θ 表示模型参数。

4. 根据权利要求3所述的一种基于新闻来源可信度的舆情知识图谱过滤方法, 其特征在于, 所述S6具体包括:

S61、对修正后的实体和关系数据 D_6 中的每条新闻数据 (E_2^i, R_2^i) 进行结构化处理, 生成初步的实体和关系集合;

$$E_2^i = \{(e_1, T_1), (e_2, T_2), \dots, (e_p, T_p)\};$$

$$R_2^i = \{(e_a, e_b, T_{ab}, W_{ab}), (e_c, e_d, T_{cd}, W_{cd}), \dots\};$$

其中, e_j 表示实体, T_j 表示时间戳, T_{ab} 和 W_{ab} 分别表示关系的时间戳和权重;

S62、定义舆情知识图谱 G 的节点集合 N 和边集合 E , 并结合新闻数据的具体属性进行改进;

$$N = \bigcup_{i=1}^n E_2^i = \bigcup_{i=1}^n \{(e_j, T_j) | j = 1, 2, \dots, p\};$$

$$E = \bigcup_{i=1}^n R_2^i = \bigcup_{i=1}^n \{(e_a, e_b, T_{ab}, W_{ab})\};$$

S63、将实体集合 N 中的每个实体 e 表示为图节点, 节点属性包括实体类型、出现频次、相关新闻来源和时间戳:

$$e = (\text{type}, \text{freq}, \text{sources}, \text{timestamp});$$

$$\text{type} = \text{EntityType}(e);$$

$$\text{freq} = \sum_{i=1}^n \delta(e \in E_2^i);$$

$$\text{sources} = \{S_0^i | e \in E_2^i\};$$

$$\text{timestamp} = \max \{T_j | e = e_j\};$$

其中, type 表示实体类型, freq 表示实体出现的频次, sources 表示相关新闻来源, timestamp 表示新闻发布时间, $\delta(e \in E_2^i)$ 是指示函数, 当 $e \in E_2^i$ 时为1, 否则为0;

S64、将关系集合 E 中的每个关系 r 表示为图边, 边属性包括关系类型、关系权重和时间戳:

$$r = (\text{type}, \text{weight}, \text{timestamp});$$

$$\text{type} = \text{RelationType}(r);$$

$$\text{weight} = \sum_{i=1}^n W_{ab};$$

$$\text{timestamp} = \max \{T_{ab} | r = (e_a, e_b)\};$$

其中, type 表示关系类型, weight 表示关系权重, timestamp 表示关系对应新闻的发布时间;

S65、利用时间序列分析方法, 根据时间戳对实体和关系进行动态更新和维护, 确保图谱的时效性;

$$\text{Update}(G, T) = \{(N', E') | \forall e_j \in N, \forall r_{ab} \in E, T_j, T_{ab} \leq T\};$$

其中, T 表示当前时间, $\text{Update}(G, T)$ 表示更新后的图谱, N' 和 E' 分别表示更新后的节点

和边集合；

S66、通过图数据库系统将实体和关系数据存储为图结构,生成初始舆情知识图谱G:

$$G = (N, E);$$

S67、根据实体的出现频次、关系的权重和新闻发布时间,对舆情知识图谱G进行优化和精简,去除噪声数据和低相关性节点及边,确保图谱的精确性和时效性;

$$N = \{e \in N | \text{freq} > \theta_f \text{ and } \text{Recency}(e, T) < \theta_t\};$$

$$E = \{r \in E | \text{weight} > \theta_w \text{ and } \text{Recency}(r, T) < \theta_t\};$$

其中, θ_f 、 θ_w 、 θ_t 为频次、权重和时间的阈值, $\text{Recency}(x, T)$ 表示节点或边相对于当前时间T的新近度。

5. 根据权利要求4所述的一种基于新闻来源可信度的舆情知识图谱过滤方法,其特征在于,所述S8具体包括:

S81、对舆情知识图谱G中的每条新闻数据进行文本情感分析,生成情感评分集合A:

$$A = \{a_1, a_2, \dots, a_m\};$$

其中, a_j 表示第j条新闻的情感评分, m为新闻总数;

S82、使用基于深度学习的情感分析模型对新闻文本进行情感分类:

$$P(c_j | d_j) = \frac{\exp(\theta_{c_j}^T f(d_j))}{\sum_c \exp(\theta_c^T f(d_j))};$$

其中, $P(c_j | d_j)$ 表示新闻 d_j 属于情感类别 c_j 的概率, θ_{c_j} 表示情感类别 c_j 的参数, $f(d_j)$ 表示新闻文本 d_j 的特征向量;

S83、对情感评分集合A进行归一化处理,生成归一化后的情感评分集合A';

S84、将归一化后的情感评分A'与舆情知识图谱G中的实体和关系进行关联,生成情感倾向增强的舆情知识图谱G':

$$G' = (N, E, A');$$

其中, N为节点集合, E为边集合, A'为归一化后的情感评分集合;

S85、对情感倾向增强的舆情知识图谱G'进行分析,识别出对特定事件或话题的舆情态度和趋势,生成舆情报告R。

6. 根据权利要求5所述的一种基于新闻来源可信度的舆情知识图谱过滤方法,其特征在于,所述S85具体包括:

S851、对舆情知识图谱G'进行主题建模,使用潜在狄利克雷分布模型提取主要话题:

$$\theta_d \sim \text{Dirichlet}(\alpha);$$

$$\phi_k \sim \text{Dirichlet}(\beta);$$

$$z_{d,n} \sim \text{Multinomial}(\theta_d);$$

$$w_{d,n} \sim \text{Multinomial}(\phi_{z_{d,n}});$$

其中, θ_d 表示文档d的话题分布, ϕ_k 表示话题k的词分布, $z_{d,n}$ 表示第d篇文档中第n个词的主题, $w_{d,n}$ 表示第d篇文档中第n个词;

S852、根据主题建模的结果,识别出每个话题的主要情感态度 sentiment_k :

$$\text{sentiment}_k = \frac{1}{|D_k|} \sum_{d \in D_k} a'_d;$$

其中, D_k 表示包含话题 k 的文档集合, a'_d 表示文档 d 的情感评分;

S853、通过时间序列分析方法, 计算每个话题的舆情趋势 trend_k :

$$\text{trend}_k = \text{Slope}(\{(t_i, a'_{d_i}) | d_i \in D_k\});$$

其中, t_i 表示时间点, a'_{d_i} 表示时间点 t_i 对应的情感评分, Slope 表示计算情感评分随时间变化的斜率;

S854、综合情感态度 sentiment_k 和舆情趋势 trend_k 生成舆情报告 R , 其中每个话题包含对应的情感态度和舆情趋势信息。

一种基于新闻来源可信度的舆情知识图谱过滤方法

技术领域

[0001] 本发明涉及舆情知识图谱技术领域,尤其涉及一种基于新闻来源可信度的舆情知识图谱过滤方法。

背景技术

[0002] 随着互联网和信息技术的迅速发展,新闻媒体和在线平台成为了获取信息的重要渠道。然而,海量的信息也带来了信息质量和可靠性的问题,尤其是在舆情分析领域,如何从众多信息源中筛选出高质量的新闻数据,成为亟待解决的技术难题。现有的舆情分析系统在处理大量新闻数据时,面临以下几个主要缺陷:

[0003] 首先,现有的舆情分析系统难以确保新闻来源的可靠性。在互联网环境下,新闻来源众多且复杂,传统的舆情分析方法通常对所有新闻数据一视同仁,缺乏对新闻来源可信度的有效评估和筛选机制。这导致低可信度的新闻信息混杂在数据集中,影响了舆情分析的准确性和可靠性。例如,一些社交媒体平台上用户生成的内容,虽然数量庞大,但其可信度往往难以保证,直接影响了分析结果的可靠性,传统的舆情知识图谱构建方法缺乏动态更新机制。舆情分析需要及时反映最新的新闻事件和舆情变化,而现有的知识图谱通常是静态的,难以根据新出现的新闻数据进行动态更新。这种缺乏时效性的知识图谱在实际应用中往往无法提供准确和及时的舆情信息,无法满足用户对实时数据的需求。此外,知识图谱的精确性也会随着时间的推移而逐渐降低,影响舆情分析的效果,现有技术在舆情分析过程中,对新闻内容的情感分析和情绪倾向评估较为粗糙。情感分析是舆情分析的重要组成部分,通过识别新闻文本中的情感倾向,可以判断公众对特定事件或话题的态度和趋势。然而,现有的情感分析技术通常只进行简单的正负面分类,无法深入理解新闻文本的复杂情感信息。例如,面对含有讽刺、幽默等复杂情感的文本,传统的情感分析技术往往难以准确识别,导致分析结果的偏差。

[0004] 此外,现有的舆情分析系统在数据处理和分析过程中,缺乏对新闻数据的深度语义理解。自然语言处理技术的发展为文本分析提供了新的方法和工具,但在舆情分析领域的应用还不够广泛和深入。传统的方法通常只进行基本的分词和词性标注,缺乏对新闻文本深层次的语义理解和分析,难以全面准确地提取出新闻中的关键信息和关系。

[0005] 最后,现有技术在舆情分析的过程中,缺乏有效的过滤机制来剔除低质量和无关的信息。大量的无关信息不仅增加了数据处理的负担,还会干扰舆情分析的结果。现有的过滤方法通常基于关键词匹配或简单的统计模型,无法根据新闻内容的实际质量和相关性进行有效的筛选,导致分析结果中仍存在大量噪声数据。

[0006] 综上所述,现有的舆情分析技术在新闻来源可信度评估、知识图谱动态更新、情感分析深度、语义理解和信息过滤等方面存在诸多缺陷,难以满足实际应用的需求。针对这些技术问题,提出一种基于新闻来源可信度的舆情知识图谱过滤方法,旨在提高舆情分析数据的可靠性和准确性,并实现舆情知识图谱的动态更新和优化,从而提供更高质量的舆情分析服务。

发明内容

[0007] 本发明的一个目的在于提出一种基于新闻来源可信度的舆情知识图谱过滤方法, 本发明有效解决了现有技术中的缺陷和不足, 实现了高质量、高时效性的舆情分析, 为用户提供了可靠的决策支持和管理参考。

[0008] 根据本发明实施例的一种基于新闻来源可信度的舆情知识图谱过滤方法, 包括如下步骤:

[0009] S1、自动从各种新闻媒体和在线平台收集新闻报道, 生成初始新闻数据集;

[0010] S2、通过建立可信度评估模型, 对初始新闻数据集中各新闻来源进行可信度分析和评价;

[0011] S3、根据可信度分析和评价结果, 过滤掉低可信度的新闻来源, 仅保留高可信度的新闻数据;

[0012] S4、使用自然语言处理技术, 对保留的新闻数据进行文本预处理, 包括分词、去停用词和句法分析;

[0013] S5、对预处理后的新闻文本进行命名实体识别和关系抽取, 生成初步的实体和关系数据;

[0014] S6、基于初步的实体和关系数据, 构建初始舆情知识图谱, 将新闻中的实体及其关系表示为结构化数据;

[0015] S7、随着新的新闻数据的出现, 动态更新舆情知识图谱;

[0016] S8、使用情感分析技术, 对舆情知识图谱中的新闻内容进行情感倾向评估, 识别出对特定事件或话题的舆情态度和趋势;

[0017] S9、基于可信度评价和情感分析结果, 对舆情知识图谱进行进一步过滤, 优化知识图谱的数据质量;

[0018] S10、基于优化后的舆情知识图谱进行舆情分析, 生成舆情报告。

[0019] 可选的, 所述S1具体包括:

[0020] S11、从各种新闻媒体和在线平台收集新闻报道数据, 其中新闻媒体包括但不限于新闻网站、社交媒体平台和博客;

[0021] S12、将收集到的新闻报道数据进行格式统一化处理, 生成初始新闻数据集 D_0 ;

[0022] S13、定义初始新闻数据集:

[0023] $D_0 = \{d_0^1, d_0^2, \dots, d_0^n\}$;

[0024] 其中, d_0^i 表示第*i*条新闻报道数据;

[0025] S14、为每条新闻报道数据 d_0^i 添加来源标签 S_0^i :

[0026] $D_1 = \{(d_0^1, S_0^1), (d_0^2, S_0^2), \dots, (d_0^n, S_0^n)\}$;

[0027] 其中, S_0^i 表示第*i*条新闻的来源;

[0028] S15、对新闻数据集 D_1 进行时间戳标记, 标记形式为 T_0^i :

[0029] $D_2 = \{(d_0^1, S_0^1, T_0^1), (d_0^2, S_0^2, T_0^2), \dots, (d_0^n, S_0^n, T_0^n)\}$;

[0030] 其中, T_0^i 表示第*i*条新闻的发布时间。

[0031] 可选的,所述S2具体包括:

[0032] S21、为每个新闻来源 S_0^i 定义一个可信度评分模型M;

[0033] S22、通过可信度评分模型M对初始新闻数据集 D_2 中的每个新闻来源进行历史数据分析,计算其可信度评分 C_0^i ;

[0034] S23、可信度评分 C_0^i 的计算公式为:

$$[0035] \quad C_0^i = \alpha \cdot f(H_0^i) + \beta \cdot g(Q_0^i) + \gamma \cdot h(R_0^i);$$

[0036] 其中, H_0^i 表示新闻来源 S_0^i 的历史可靠性, Q_0^i 表示新闻报道质量, R_0^i 表示新闻来源的专家评价, α 、 β 、 γ 为权重系数;

[0037] S24、对每个新闻来源 S_0^i 进行多维度数据收集,包括新闻发布频率 F_0^i 、历史准确性 A_0^i 、用户反馈 U_0^i ;

$$[0038] \quad H_0^i = \frac{1}{N} \sum_{j=1}^N \left(\frac{1}{1+e^{-(P_0^i(j)-\mu_p)}} \right);$$

[0039] 其中, $P_0^i(j)$ 表示新闻来源 S_0^i 在第j条新闻中的准确性评分, μ_p 为准确性评分的平均值,N为新闻总数;

$$[0040] \quad Q_0^i = \sqrt{\frac{1}{M} \sum_{k=1}^M (Q_{0k}^i - \bar{Q}_0^i)^2};$$

[0041] 其中, Q_{0k}^i 表示新闻k的质量评分, $\bar{Q}_0^i$ 为新闻来源 S_0^i 的平均质量评分,M为质量评分总数;

$$[0042] \quad R_0^i = \sum_{l=1}^L E_0^i(l) \cdot w_l;$$

[0043] 其中, $E_0^i(l)$ 表示专家1对新闻来源 S_0^i 的评分, w_1 为专家1的权重,L为参与评分的专家总数;

[0044] S25、将多维度数据输入可信度评分模型M,计算综合可信度评分 C_0^i ,并进行归一化处理;

[0045] S26、根据可信度评分集C,对初始新闻数据集 D_2 进行筛选,仅保留可信度评分 C_0^i 高于预设阈值 T_c 的新闻数据,生成可信新闻数据集 D_3 ;

$$[0046] \quad D_3 = \{d_0^i \in D_2 | C_0^i > T_c\}.$$

[0047] 可选的,所述S4具体包括:

[0048] S41、对可信新闻数据集 D_3 中的每条新闻数据 d_0^i 进行分词处理,生成词序列 W_0^i ;

[0049] S42、对词序列 W_0^i 进行去停用词处理,移除常见但无意义的词语,生成净化后的词序列 W_1^i ;

[0050] S43、对净化后的词序列 W_1^i 进行句法分析,生成句法结构 S_1^i ,包括词性标注和依存关系分析:

$$[0051] \quad S_1^i = \{(w_1^i(k), pos_1^i(k), dep_1^i(k)) | k = 1, 2, \dots, n\};$$

[0052] 其中, $pos_1^i(k)$ 表示词 $w_1^i(k)$ 的词性, $dep_1^i(k)$ 表示词 $w_1^i(k)$ 与其他词的依存关系;

[0053] S44、将经过分词、去停用词和句法分析处理后的新闻数据 S_1^i 作为输入,生成预处理后的新闻数据集 D_4 。

[0054] 可选的,所述S5具体包括:

[0055] S51、对预处理后的新闻数据集 D_4 中的每条新闻数据 S_1^i 使用增强型预训练语言模型BERT进行深度语义理解,生成包含上下文信息的嵌入向量 V_1^i :

$$[0056] \quad V_1^i = \{v_1^i(1), v_1^i(2), \dots, v_1^i(n)\};$$

[0057] 其中, $v_1^i(j)$ 表示新闻数据 S_1^i 中第j个词的上下文嵌入向量, n为词的总数。具体生成嵌入向量的公式如下:

$$[0058] \quad v_1^i(j) = BERT(W_1^i(j), \{W_1^i(1), W_1^i(2), \dots, W_1^i(n)\});$$

[0059] 其中, BERT表示BERT模型, $W_1^i(j)$ 表示第j个词及其上下文词语;

[0060] S52、利用基于变换器的命名实体识别模型SpanBERT对嵌入向量 $v_1^i(j)$ 进行实体识别,生成包含实体边界和类别的集合 E_2^i :

$$[0061] \quad E_2^i = \{(b_1, e_1, c_1), (b_2, e_2, c_2), \dots, (b_p, e_p, c_p)\};$$

[0062] 其中, b_j 和 e_j 分别表示第j个实体的起始和结束位置, c_j 表示实体类别, p为识别出的实体总数,具体识别过程如下:

$$[0063] \quad P(e_j|v_1^i) = \frac{\exp(\text{SpanBERT}(v_1^i) \cdot W_{c_j} + b_{c_j})}{\sum_c \exp(\text{SpanBERT}(v_1^i) \cdot W_c + b_c)};$$

[0064] 其中, $P(e_j|v_1^i)$ 表示实体 e_j 的概率, SpanBERT表示SpanBERT模型, W_{c_j} 和 b_{c_j} 分别表示类别 c_j 的权重和偏置;

[0065] S53、利用基于图神经网络的关系抽取模型,对实体集合 E_2^i 及其上下文嵌入向量进行关系推断,生成关系集合 R_2^i :

$$[0066] \quad R_2^i = \{(e_2^i(a), e_2^i(b), t_2^i(k)) | a, b \in \{1, 2, \dots, p\}\};$$

[0067] 其中, $t_2^i(k)$ 表示实体对 $(e_2^i(a), e_2^i(b))$ 的关系类型,包括合作、冲突、隶属,关系推断的具体公式如下:

$$h_{e_2^i(a), e_2^i(b)}^{(l+1)} = \sigma(W^{(l)} \cdot \sum_{e_2^i(m) \in N(e_2^i(a), e_2^i(b))} \alpha_{am}^{(l)} h_{e_2^i(m)}^{(l)});$$

$$[0068] \quad \alpha_{am}^{(l)} = \frac{\exp(\text{LeakyReLU}(a^T [W^{(l)} h_{e_2^i(a)}^{(l)} \| W^{(l)} h_{e_2^i(m)}^{(l)}])))}{\sum_{e_2^i(n) \in N(e_2^i(a))} \exp(\text{LeakyReLU}(a^T [W^{(l)} h_{e_2^i(a)}^{(l)} \| W^{(l)} h_{e_2^i(n)}^{(l)}])));$$

[0069] 其中, $h_{e_2^i(a), e_2^i(b)}^{(l+1)}$ 表示第l+1层中实体 $e_2^i(a), e_2^i(b)$ 的嵌入向量, $N(e_2^i(a), e_2^i(b))$ 表示实体对的邻居集合, $W^{(l)}$ 表示第l层的权重矩阵, $\alpha_{am}^{(l)}$ 表示注意力系数, a表示注意力机制的参

数向量, // 表示向量连接操作;

[0070] S54、使用自监督学习方法对实体和关系数据进行验证和修正,确保其准确性和一致性,生成修正后的实体和关系数据 D_6 :

[0071] $D_6 = \{(E_2^i, R_2^i) | i = 1, 2, \dots, n\}$;

[0072] 验证和修正的具体过程如下:

[0073] $\mathcal{L}_{self} = - \sum_{(e_2^i(a), e_2^i(b)) \in R_2^i} \log P(t_2^i(k) | e_2^i(a), e_2^i(b)) + \lambda \sum_{i=1}^n \|\Theta\|^2$;

[0074] 其中, $\mathcal{L}_{self}$ 表示自监督学习的损失函数, $P(t_2^i(k) | e_2^i(a), e_2^i(b))$ 表示给定实体对 $(e_2^i(a), e_2^i(b))$ 的关系类型 $t_2^i(k)$ 的概率, λ 为正则化参数, Θ 表示模型参数。

[0075] 可选的,所述S6具体包括:

[0076] S61、对修正后的实体和关系数据 D_6 中的每条新闻数据 (E_2^i, R_2^i) 进行结构化处理,生成初步的实体和关系集合;

$$E_2^i = \{(e_1, T_1), (e_2, T_2), \dots, (e_p, T_p)\};$$

[0077]

$$R_2^i = \{(e_a, e_b, T_{ab}, W_{ab}), (e_c, e_d, T_{cd}, W_{cd}), \dots\};$$

[0078] 其中, e_j 表示实体, T_j 表示时间戳, T_{ab} 和 W_{ab} 分别表示关系的时间戳和权重;

[0079] S62、定义舆情知识图谱G的节点集合N和边集合E,并结合新闻数据的具体属性进行改进;

$$N = \bigcup_{i=1}^n E_2^i = \bigcup_{i=1}^n \{(e_j, T_j) | j = 1, 2, \dots, p\};$$

[0080]

$$E = \bigcup_{i=1}^n R_2^i = \bigcup_{i=1}^n \{(e_a, e_b, T_{ab}, W_{ab})\};$$

[0081] S63、将实体集合N中的每个实体e表示为图节点,节点属性包括实体类型、出现频次、相关新闻来源和时间戳:

[0082] $e = (\text{type}, \text{freq}, \text{sources}, \text{timestamp})$;

[0083] $\text{type} = \text{EntityType}(e)$;

$$\text{freq} = \sum_{i=1}^n \delta(e \in E_2^i);$$

[0084]

$$\text{sources} = \{S_0^i | e \in E_2^i\};$$

[0085] $\text{timestamp} = \max\{T_j | e = e_j\}$;

[0086] 其中, type 表示实体类型, freq 表示实体出现的频次, sources 表示相关新闻来源, timestamp 表示新闻发布时间, $\delta(e \in E_2^i)$ 是指示函数, 当 $e \in E_2^i$ 时为1, 否则为0;

[0087] S64、将关系集合E中的每个关系r表示为图边,边属性包括关系类型、关系权重和时间戳:

[0088] $r = (\text{type}, \text{weight}, \text{timestamp})$;

[0089] $\text{type} = \text{RelationType}(r)$;

[0090] $\text{weight} = \sum_{i=1}^n W_{ab}$;

[0091] $\text{timestamp} = \max\{T_{ab} | r = (e_a, e_b)\}$;

[0092] 其中, type表示关系类型, weight表示关系权重, timestamp表示关系对应新闻的发布时间;

[0093] S65、利用时间序列分析方法, 根据时间戳对实体和关系进行动态更新和维护, 确保图谱的时效性;

[0094] $Update(G, T) = \{(N', E') | \forall e_j \in N, \forall r_{ab} \in E, T_j, T_{ab} \leq T\}$;

[0095] 其中, T表示当前时间, Update(G, T)表示更新后的图谱, N'和E'分别表示更新后的节点和边集合;

[0096] S66、通过图数据库系统将实体和关系数据存储为图结构, 生成初始舆情知识图谱G;

[0097] $G = (N, E)$;

[0098] S67、根据实体的出现频次、关系的权重和新闻发布时间, 对舆情知识图谱G进行优化和精简, 去除噪声数据和低相关性节点及边, 确保图谱的精确性和时效性;

[0099] $N = \{e \in N | \text{freq} > \theta_f \text{ and Recency}(e, T) < \theta_t\}$;

[0100] $E = \{r \in E | \text{weight} > \theta_w \text{ and Recency}(r, T) < \theta_t\}$;

[0101] 其中, θ_f 、 θ_w 、 θ_t 为频次、权重和时间的阈值, Recency(x, T)表示节点或边相对于当前时间T的新近度。

[0102] 可选的, 所述S8具体包括:

[0103] S81、对舆情知识图谱G中的每条新闻数据进行文本情感分析, 生成情感评分集合A:

[0104] $A = \{a_1, a_2, \dots, a_m\}$;

[0105] 其中, a_j 表示第j条新闻的情感评分, m为新闻总数;

[0106] S82、使用基于深度学习的情感分析模型对新闻文本进行情感分类:

[0107]
$$P(c_j | d_j) = \frac{\exp(\theta_{c_j}^T f(d_j))}{\sum_c \exp(\theta_c^T f(d_j))};$$

[0108] 其中, $P(c_j | d_j)$ 表示新闻 d_j 属于情感类别 c_j 的概率, θ_{c_j} 表示情感类别 c_j 的参数, $f(d_j)$ 表示新闻文本 d_j 的特征向量;

[0109] S83、对情感评分集合A进行归一化处理, 生成归一化后的情感评分集合A';

[0110] S84、将归一化后的情感评分A'与舆情知识图谱G中的实体和关系进行关联, 生成情感倾向增强的舆情知识图谱G':

[0111] $G' = (N, E, A')$;

[0112] 其中, N为节点集合, E为边集合, A'为归一化后的情感评分集合;

[0113] S85、对情感倾向增强的舆情知识图谱G'进行分析, 识别出对特定事件或话题的舆情态度和趋势, 生成舆情报告R。

[0114] 可选的, 所述S85具体包括:

[0115] S851、对舆情知识图谱G'进行主题建模, 使用潜在狄利克雷分布模型提取主要话题:

[0116] $\theta_d \sim \text{Dirichlet}(\alpha)$;

[0117] $\varphi_k \sim \text{Dirichlet}(\beta)$;

[0118] $z_{d,n} \sim \text{Multinomial}(\theta_d)$;

[0119] $w_{d,n} \sim \text{Multinomial}(\varphi_{z_{d,n}})$;

[0120] 其中, θ_d 表示文档d的话题分布, φ_k 表示话题k的词分布, $z_{d,n}$ 表示第d篇文档中第n个词的主题, $w_{d,n}$ 表示第d篇文档中第n个词;

[0121] S852、根据主题建模的结果,识别出每个话题的主要情感态度 sentiment_k :

[0122] $\text{sentiment}_k = \frac{1}{|D_k|} \sum_{d \in D_k} a'_d$;

[0123] 其中, D_k 表示包含话题k的文档集合, a'_d 表示文档d的情感评分;

[0124] S853、通过时间序列分析方法,计算每个话题的舆情趋势 trend_k :

[0125] $\text{trend}_k = \text{Slope}(\{(t_i, a'_{d_i}) | d_i \in D_k\})$;

[0126] 其中, t_i 表示时间点, a'_{d_i} 表示时间点 t_i 对应的情感评分, Slope 表示计算情感评分随时间变化的斜率;

[0127] S854、综合情感态度 sentiment_k 和舆情趋势 trend_k 生成舆情报告R,其中每个话题包含对应的情感态度和舆情趋势信息。

[0128] 本发明的有益效果是:

[0129] (1) 本发明通过建立可信度评估模型,对新闻来源进行可信度分析和评价,确保仅保留高可信度的新闻数据,通过基于历史数据、新闻质量和专家评分的多维度数据收集和评估模型,有效过滤掉低可信度的新闻来源,显著提高了输入数据的质量,进而提高了舆情分析结果的可靠性和准确性。

[0130] (2) 本发明通过对修正后的实体和关系数据进行结构化处理,构建初始舆情知识图谱,并利用时间序列分析方法,根据时间戳对实体和关系进行动态更新和维护,确保了舆情知识图谱能够实时反映最新的新闻信息,保持数据的时效性和精确性。

[0131] (3) 本发明使用基于深度学习的情感分析模型对新闻文本进行情感分类和评估,通过详细描述的情感评分计算和归一化处理,结合舆情知识图谱中的实体和关系,生成情感倾向增强的舆情知识图谱,不仅提高了情感分析的深度,还能识别出对特定事件或话题的复杂情感倾向,生成更加全面和准确的舆情报告。

[0132] (4) 本发明在多个步骤中引入了多层次的过滤机制,通过可信度评估结果过滤低可信度新闻数据,基于情感分析和可信度评价结果进一步过滤知识图谱中的低可信度信息,并根据实体的出现频次、关系的权重和新闻发布时间对舆情知识图谱进行优化和精简。

附图说明

[0133] 附图用来提供对本发明的进一步理解,并且构成说明书的一部分,与本发明的实施例一起用于解释本发明,并不构成对本发明的限制。在附图中:

[0134] 图1为本发明提出的一种基于新闻来源可信度的舆情知识图谱过滤方法的流程图;

[0135] 图2为本发明提出的一种基于新闻来源可信度的舆情知识图谱过滤方法的构建初始舆情知识图谱的具体步骤流程图。

具体实施方式

[0136] 现在结合附图对本发明作进一步详细的说明。这些附图均为简化的示意图,仅以示意方式说明本发明的基本结构,因此其仅显示与本发明有关的构成。

[0137] 参考图1-2,一种基于新闻来源可信度的舆情知识图谱过滤方法,包括如下步骤:

[0138] S1、自动从各种新闻媒体和在线平台收集新闻报道,生成初始新闻数据集;

[0139] S2、通过建立可信度评估模型,对初始新闻数据集中各新闻来源进行可信度分析和评价;

[0140] S3、根据可信度分析和评价结果,过滤掉低可信度的新闻来源,仅保留高可信度的新闻数据;

[0141] S4、使用自然语言处理技术,对保留的新闻数据进行文本预处理,包括分词、去停用词和句法分析;

[0142] S5、对预处理后的新闻文本进行命名实体识别和关系抽取,生成初步的实体和关系数据;

[0143] S6、基于初步的实体和关系数据,构建初始舆情知识图谱,将新闻中的实体及其关系表示为结构化数据;

[0144] S7、随着新的新闻数据的出现,动态更新舆情知识图谱;

[0145] S8、使用情感分析技术,对舆情知识图谱中的新闻内容进行情感倾向评估,识别出对特定事件或话题的舆情态度和趋势;

[0146] S9、基于可信度评价和情感分析结果,对舆情知识图谱进行进一步过滤,优化知识图谱的数据质量;

[0147] S10、基于优化后的舆情知识图谱进行舆情分析,生成舆情报告。

[0148] 本实施方式中,S1具体包括:

[0149] S11、从各种新闻媒体和在线平台收集新闻报道数据,其中新闻媒体包括但不限于新闻网站、社交媒体平台和博客;

[0150] S12、将收集到的新闻报道数据进行格式统一化处理,生成初始新闻数据集 D_0 ;

[0151] S13、定义初始新闻数据集:

[0152] $D_0 = \{d_0^1, d_0^2, \dots, d_0^n\}$;

[0153] 其中, d_0^i 表示第i条新闻报道数据;

[0154] S14、为每条新闻报道数据 d_0^i 添加来源标签 S_0^i :

[0155] $D_1 = \{(d_0^1, S_0^1), (d_0^2, S_0^2), \dots, (d_0^n, S_0^n)\}$;

[0156] 其中, S_0^i 表示第i条新闻的来源;

[0157] S15、对新闻数据集 D_1 进行时间戳标记,标记形式为 T_0^i :

[0158] $D_2 = \{(d_0^1, S_0^1, T_0^1), (d_0^2, S_0^2, T_0^2), \dots, (d_0^n, S_0^n, T_0^n)\}$;

[0159] 其中, T_0^i 表示第i条新闻的发布时间。

[0160] 本实施方式中,S2具体包括:

[0161] S21、为每个新闻来源 S_0^i 定义一个可信度评分模型M;

[0162] S22、通过可信度评分模型M对初始新闻数据集 D_2 中的每个新闻来源进行历史数据分析,计算其可信度评分 C_0^i ;

[0163] S23、可信度评分 C_0^i 的计算公式为:

$$[0164] \quad C_0^i = \alpha \cdot f(H_0^i) + \beta \cdot g(Q_0^i) + \gamma \cdot h(R_0^i);$$

[0165] 其中, H_0^i 表示新闻来源 S_0^i 的历史可靠性, Q_0^i 表示新闻报道质量, R_0^i 表示新闻来源的专家评价, α 、 β 、 γ 为权重系数;

[0166] S24、对每个新闻来源 S_0^i 进行多维度数据收集,包括新闻发布频率 F_0^i 、历史准确性 A_0^i 、用户反馈 U_0^i ;

$$[0167] \quad H_0^i = \frac{1}{N} \sum_{j=1}^N \left(\frac{1}{1 + e^{-(P_0^i(j) - \mu_p)}} \right);$$

[0168] 其中, $P_0^i(j)$ 表示新闻来源 S_0^i 在第j条新闻中的准确性评分, μ_p 为准确性评分的平均值,N为新闻总数;

$$[0169] \quad Q_0^i = \sqrt{\frac{1}{M} \sum_{k=1}^M (Q_{0k}^i - \bar{Q}_0^i)^2};$$

[0170] 其中, Q_{0k}^i 表示新闻k的质量评分, $\bar{Q}_0^i$ 为新闻来源 S_0^i 的平均质量评分,M为质量评分总数;

$$[0171] \quad R_0^i = \sum_{l=1}^L E_0^i(l) \cdot w_l;$$

[0172] 其中, $E_0^i(l)$ 表示专家l对新闻来源 S_0^i 的评分, w_l 为专家l的权重,L为参与评分的专家总数;

[0173] S25、将多维度数据输入可信度评分模型M,计算综合可信度评分 C_0^i ,并进行归一化处理;

[0174] S26、根据可信度评分集C,对初始新闻数据集 D_2 进行筛选,仅保留可信度评分 C_0^i 高于预设阈值 T_c 的新闻数据,生成可信新闻数据集 D_3 ;

$$[0175] \quad D_3 = \{d_0^i \in D_2 | C_0^i > T_c\}.$$

[0176] 本实施方式中,S4具体包括:

[0177] S41、对可信新闻数据集 D_3 中的每条新闻数据 d_0^i 进行分词处理,生成词序列 W_0^i ;

[0178] S42、对词序列 W_0^i 进行去停用词处理,移除常见但无意义的词语,生成净化后的词序列 W_1^i ;

[0179] S43、对净化后的词序列 W_1^i 进行句法分析,生成句法结构 S_1^i ,包括词性标注和依存关系分析;

$$[0180] \quad S_1^i = \{(w_1^i(k), pos_1^i(k), dep_1^i(k)) | k = 1, 2, \dots, n\};$$

[0181] 其中, $pos_1^i(k)$ 表示词 $w_1^i(k)$ 的词性, $dep_1^i(k)$ 表示词 $w_1^i(k)$ 与其他词的依存关系;

[0182] S44、将经过分词、去停用词和句法分析处理后的新闻数据 S_1^i 作为输入,生成预处

理后的新闻数据集 D_4 。

[0183] 本实施方式中, S5具体包括:

[0184] S51、对预处理后的新闻数据集 D_4 中的每条新闻数据 S_1^i 使用增强型预训练语言模型BERT进行深度语义理解,生成包含上下文信息的嵌入向量 V_1^i :

[0185] $V_1^i = \{v_1^i(1), v_1^i(2), \dots, v_1^i(n)\}$;

[0186] 其中, $v_1^i(j)$ 表示新闻数据 S_1^i 中第j个词的上下文嵌入向量, n为词的总数。具体生成嵌入向量的公式如下:

[0187] $v_1^i(j) = \text{BERT}(W_1^i(j), \{W_1^i(1), W_1^i(2), \dots, W_1^i(n)\})$;

[0188] 其中, BERT表示BERT模型, $W_1^i(j)$ 表示第j个词及其上下文词语;

[0189] S52、利用基于变换器的命名实体识别模型SpanBERT对嵌入向量 $v_1^i(j)$ 进行实体识别,生成包含实体边界和类别的集合 E_2^i :

[0190] $E_2^i = \{(b_1, e_1, c_1), (b_2, e_2, c_2), \dots, (b_p, e_p, c_p)\}$;

[0191] 其中, b_j 和 e_j 分别表示第j个实体的起始和结束位置, c_j 表示实体类别, p为识别出的实体总数,具体识别过程如下:

[0192] $P(e_j|v_1^i) = \frac{\exp(\text{SpanBERT}(v_1^i) \cdot W_{c_j} + b_{c_j})}{\sum_{c'} \exp(\text{SpanBERT}(v_1^i) \cdot W_{c'} + b_{c'})}$;

[0193] 其中, $P(e_j|v_1^i)$ 表示实体 e_j 的概率, SpanBERT表示SpanBERT模型, W_{c_j} 和 b_{c_j} 分别表示类别 c_j 的权重和偏置;

[0194] S53、利用基于图神经网络的关系抽取模型,对实体集合 E_2^i 及其上下文嵌入向量进行关系推断,生成关系集合 R_2^i :

[0195] $R_2^i = \{(e_2^i(a), e_2^i(b), t_2^i(k)) | a, b \in \{1, 2, \dots, p\}\}$;

[0196] 其中, $t_2^i(k)$ 表示实体对 $(e_2^i(a), e_2^i(b))$ 的关系类型,包括合作、冲突、隶属,关系推断的具体公式如下:

[0197] $h_{e_2^i(a), e_2^i(b)}^{(l+1)} = \sigma(W^{(l)} \cdot \sum_{e_2^i(m) \in N(e_2^i(a), e_2^i(b))} \alpha_{am}^{(l)} h_{e_2^i(m)}^{(l)})$;

[0197] $\alpha_{am}^{(l)} = \frac{\exp(\text{LeakyReLU}(a^T [W^{(l)} h_{e_2^i(a)}^{(l)} \| W^{(l)} h_{e_2^i(m)}^{(l)}])))}{\sum_{e_2^i(n) \in N(e_2^i(a))} \exp(\text{LeakyReLU}(a^T [W^{(l)} h_{e_2^i(a)}^{(l)} \| W^{(l)} h_{e_2^i(n)}^{(l)}])))}$;

[0198] 其中, $h_{e_2^i(a), e_2^i(b)}^{(l+1)}$ 表示第l+1层中实体 $e_2^i(a), e_2^i(b)$ 的嵌入向量, $N(e_2^i(a), e_2^i(b))$ 表示实体对的邻居集合, $W^{(l)}$ 表示第l层的权重矩阵, $\alpha_{am}^{(l)}$ 表示注意力系数, a表示注意力机制的参数向量, // 表示向量连接操作;

[0199] S54、使用自监督学习方法对实体和关系数据进行验证和修正,确保其准确性和一致性,生成修正后的实体和关系数据 D_6 :

[0200] $D_6 = \{(E_2^i, R_2^i) | i = 1, 2, \dots, n\};$

[0201] 验证和修正的具体过程如下:

[0202] $\mathcal{L}_{self} = - \sum_{(e_2^i(a), e_2^i(b)) \in R_2^i} \log P(t_2^i(k) | e_2^i(a), e_2^i(b)) + \lambda \sum_{i=1}^n \|\Theta\|^2;$

[0203] 其中, $\mathcal{L}_{self}$ 表示自监督学习的损失函数, $P(t_2^i(k) | e_2^i(a), e_2^i(b))$ 表示给定实体对 $(e_2^i(a), e_2^i(b))$ 的关系类型 $t_2^i(k)$ 的概率, λ 为正则化参数, Θ 表示模型参数。

[0204] 本实施方式中, S6具体包括:

[0205] S61、对修正后的实体和关系数据 D_6 中的每条新闻数据 (E_2^i, R_2^i) 进行结构化处理, 生成初步的实体和关系集合;

$$E_2^i = \{(e_1, T_1), (e_2, T_2), \dots, (e_p, T_p)\};$$

[0206]

$$R_2^i = \{(e_a, e_b, T_{ab}, W_{ab}), (e_c, e_d, T_{cd}, W_{cd}), \dots\};$$

[0207] 其中, e_j 表示实体, T_j 表示时间戳, T_{ab} 和 W_{ab} 分别表示关系的时间戳和权重;

[0208] S62、定义舆情知识图谱 G 的节点集合 N 和边集合 E , 并结合新闻数据的具体属性进行改进;

$$N = \bigcup_{i=1}^n E_2^i = \bigcup_{i=1}^n \{(e_j, T_j) | j = 1, 2, \dots, p\};$$

[0209]

$$E = \bigcup_{i=1}^n R_2^i = \bigcup_{i=1}^n \{(e_a, e_b, T_{ab}, W_{ab})\};$$

[0210] S63、将实体集合 N 中的每个实体 e 表示为图节点, 节点属性包括实体类型、出现频次、相关新闻来源和时间戳:

[0211] $e = (\text{type}, \text{freq}, \text{sources}, \text{timestamp});$

[0212] $\text{type} = \text{EntityType}(e);$

$$\text{freq} = \sum_{i=1}^n \delta(e \in E_2^i);$$

[0213]

$$\text{sources} = \{S_0^i | e \in E_2^i\};$$

[0214] $\text{timestamp} = \max\{T_j | e = e_j\};$

[0215] 其中, type 表示实体类型, freq 表示实体出现的频次, sources 表示相关新闻来源, timestamp 表示新闻发布时间, $\delta(e \in E_2^i)$ 是指示函数, 当 $e \in E_2^i$ 时为1, 否则为0;

[0216] S64、将关系集合 E 中的每个关系 r 表示为图边, 边属性包括关系类型、关系权重和时间戳:

[0217] $r = (\text{type}, \text{weight}, \text{timestamp});$

[0218] $\text{type} = \text{RelationType}(r);$

[0219] $\text{weight} = \sum_{i=1}^n W_{ab};$

[0220] $\text{timestamp} = \max\{T_{ab} | r = (e_a, e_b)\};$

[0221] 其中, type 表示关系类型, weight 表示关系权重, timestamp 表示关系对应新闻的发布时间;

[0222] S65、利用时间序列分析方法, 根据时间戳对实体和关系进行动态更新和维护, 确

保图谱的时效性;

[0223] $Update(G, T) = \{(N', E') | \forall e_j \in N, \forall r_{ab} \in E, T_j, T_{ab} \leq T\}$;

[0224] 其中, T表示当前时间, Update(G, T)表示更新后的图谱, N'和E'分别表示更新后的节点和边集合;

[0225] S66、通过图数据库系统将实体和关系数据存储为图结构,生成初始舆情知识图谱G;

[0226] $G = (N, E)$;

[0227] S67、根据实体的出现频次、关系的权重和新闻发布时间,对舆情知识图谱G进行优化和精简,去除噪声数据和低相关性节点及边,确保图谱的精确性和时效性;

[0228] $N' = \{e \in N | \text{freq} > \theta_f \text{ and } \text{Recency}(r, T) < \theta_t\}$;

[0229] $E' = \{r \in E | \text{weight} > \theta_w \text{ and } \text{Recency}(r, T) < \theta_t\}$;

[0230] 其中, θ_f 、 θ_w 、 θ_t 为频次、权重和时间的阈值, Recency(x, T)表示节点或边相对于当前时间T的新近度。

[0231] 本实施方式中, S8具体包括:

[0232] S81、对舆情知识图谱G中的每条新闻数据进行文本情感分析,生成情感评分集合A;

[0233] $A = \{a_1, a_2, \dots, a_m\}$;

[0234] 其中, a_j 表示第j条新闻的情感评分, m为新闻总数;

[0235] S82、使用基于深度学习的情感分析模型对新闻文本进行情感分类:

[0236]
$$P(c_j | d_j) = \frac{\exp(\theta_{c_j}^T f(d_j))}{\sum_c \exp(\theta_c^T f(d_j))};$$

[0237] 其中, $P(c_j | d_j)$ 表示新闻 d_j 属于情感类别 c_j 的概率, θ_{c_j} 表示情感类别 c_j 的参数, $f(d_j)$ 表示新闻文本 d_j 的特征向量;

[0238] S83、对情感评分集合A进行归一化处理,生成归一化后的情感评分集合A';

[0239] S84、将归一化后的情感评分A'与舆情知识图谱G中的实体和关系进行关联,生成情感倾向增强的舆情知识图谱G';

[0240] $G' = (N, E, A')$;

[0241] 其中, N为节点集合, E为边集合, A'为归一化后的情感评分集合;

[0242] S85、对情感倾向增强的舆情知识图谱G'进行分析,识别出对特定事件或话题的舆情态度和趋势,生成舆情报告R。

[0243] 本实施方式中, S85具体包括:

[0244] S851、对舆情知识图谱G'进行主题建模,使用潜在狄利克雷分布模型提取主要话题:

[0245] $\theta_d \sim \text{Dirichlet}(\alpha)$;

[0246] $\varphi_k \sim \text{Dirichlet}(\beta)$;

[0247] $z_{d,n} \sim \text{Multinomial}(\theta_d)$;

[0248] $w_{d,n} \sim \text{Multinomial}(\varphi_{z_{d,n}})$;

[0249] 其中, θ_d 表示文档d的话题分布, φ_k 表示话题k的词分布, $z_{d,n}$ 表示第d篇文档中第n个词的主题, $w_{d,n}$ 表示第d篇文档中第n个词;

[0250] S852、根据主题建模的结果,识别出每个话题的主要情感态度 sentiment_k ;

$$[0251] \quad \text{sentiment}_k = \frac{1}{|D_k|} \sum_{d \in D_k} a'_d;$$

[0252] 其中, D_k 表示包含话题k的文档集合, a'_d 表示文档d的情感评分;

[0253] S853、通过时间序列分析方法,计算每个话题的舆情趋势 trend_k ;

$$[0254] \quad \text{trend}_k = \text{Slope}(\{(t_i, a'_{d_i}) | d_i \in D_k\});$$

[0255] 其中, t_i 表示时间点, a'_{d_i} 表示时间点 t_i 对应的情感评分, Slope 表示计算情感评分随时间变化的斜率;

[0256] S854、综合情感态度 sentiment_k 和舆情趋势 trend_k 生成舆情报告R,其中每个话题包含对应的情感态度和舆情趋势信息。

[0257] 实施例1:在本实施例中,选择一个重要的社会事件作为分析对象,模拟新闻报道的收集、分析和过滤过程。具体事件为某国际体育赛事举办期间发生的一起突发事件。该事件在多个新闻媒体和社交平台上广泛传播,生成了大量新闻报道和用户评论。舆情分析的目标是识别公众对这一事件的态度和趋势,并及时反映在舆情知识图谱中,以供相关部门进行决策和管理。

[0258] 在这一场景中,首先从各种新闻媒体和在线平台自动收集有关该体育赛事突发事件的新闻报道数据,生成初始新闻数据集。这包括从新闻网站、社交媒体平台、博客等多种渠道获取的数据。为了确保数据的质量和可信度,使用本发明的方法对新闻来源进行可信度评估,并过滤掉低可信度的新闻来源,仅保留高可信度的新闻数据。

[0259] 接下来,对保留的新闻数据进行文本预处理,包括分词、去停用词和句法分析。然后,利用命名实体识别和关系抽取技术,从预处理后的新闻文本中提取出关键实体和关系数据,生成初步的实体和关系数据。

[0260] 基于初步的实体和关系数据,构建初始舆情知识图谱,将新闻中的实体及其关系表示为结构化数据。随着新新闻数据的出现,通过动态更新机制,实时更新舆情知识图谱,确保其时效性和准确性。

[0261] 随后,使用情感分析技术,对舆情知识图谱中的新闻内容进行情感倾向评估,识别出公众对特定事件或话题的舆情态度和趋势,并生成情感倾向增强的舆情知识图谱。

[0262] 最后,基于优化后的舆情知识图谱进行舆情分析,生成舆情报告,并通过可视化界面展示分析结果,为相关部门提供高质量的决策支持。

[0263] 在本实施例中,我们选择了某一国际体育赛事突发事件的新闻报道进行模拟。共收集了来自20个新闻媒体和在线平台的5000条新闻报道数据,其中包括新闻网站(例如今日头条)、社交媒体平台(例如新浪微博)等。

[0264] 通过可信度评估模型,对这些新闻来源进行可信度分析,过滤掉低可信度的新闻来源,最终保留了15个新闻来源,共计3000条高可信度的新闻数据。这些高可信度的新闻数据经过文本预处理后,生成了包含关键词、实体和关系的数据集。

[0265] 利用命名实体识别技术,从新闻文本中提取出涉及突发事件的关键实体,例如“赛

事名称”、“突发事件描述”、“相关人员姓名”等。关系抽取技术进一步识别出这些实体之间的关系,例如“参与”、“影响”、“报道”等,最终生成初步的实体和关系数据。

[0266] 基于这些实体和关系数据,构建初始舆情知识图谱。随着赛事的进行和新的新闻报道的出现,动态更新舆情知识图谱,确保其包含最新的新闻数据。

[0267] 使用情感分析技术,对新闻内容进行情感倾向评估。结果显示,60%的新闻报道对事件持负面态度,30%的报道持中立态度,10%的报道持正面态度。这些情感倾向数据被整合到舆情知识图谱中,生成情感倾向增强的舆情知识图谱。

[0268] 为了验证本发明方法的有效性,将本发明的方法与传统的舆情分析方法进行对比。以下是对比数据:

[0269] 表1本发明的方法与传统的舆情分析方法进行对比

[0270]

指标	本发明方法	传统方法
数据处理时间(小时)	2	5
高可信度数据比例	60%	40%
情感分类准确率	85%	70%
知识图谱更新频率	实时更新	每日一次
噪声数据比例	5%	20%
决策支持满意度	90%	65%

[0271] 上述表1的数据表明,本发明的方法在多个关键指标上均显著优于传统方法。具体而言,本发明的方法通过可信度评估模型有效提高了高可信度数据的比例,显著减少了数据处理时间,提高了情感分类的准确率和知识图谱的更新频率。同时,噪声数据比例显著降低,决策支持满意度明显提升。

[0272] 通过上述实施例,充分展示了本发明方法在舆情分析中的实际应用效果,有效解决了现有技术中的数据质量、时效性和准确性问题,为舆情分析提供了强有力的技术支持。

[0273] 本发明通过建立可信度评估模型,对新闻来源进行可信度分析和评价,确保仅保留高可信度的新闻数据,通过基于历史数据、新闻质量和专家评分的多维度数据收集和评估模型,有效过滤掉低可信度的新闻来源,显著提高了输入数据的质量,进而提高了舆情分析结果的可靠性和准确性。

[0274] 本发明通过对修正后的实体和关系数据进行结构化处理,构建初始舆情知识图谱,并利用时间序列分析方法,根据时间戳对实体和关系进行动态更新和维护,确保了舆情知识图谱能够实时反映最新的新闻信息,保持数据的时效性和精确性。

[0275] 本发明使用基于深度学习的情感分析模型对新闻文本进行情感分类和评估,通过详细描述的情感评分计算和归一化处理,结合舆情知识图谱中的实体和关系,生成情感倾向增强的舆情知识图谱,不仅提高了情感分析的深度,还能识别出对特定事件或话题的复杂情感倾向,生成更加全面和准确的舆情报告。

[0276] 本发明在多个步骤中引入了多层次的过滤机制,通过可信度评估结果过滤低可信度新闻数据,基于情感分析和可信度评价结果进一步过滤知识图谱中的低可信度信息,并根据实体的出现频次、关系的权重和新闻发布时间对舆情知识图谱进行优化和精简。

[0277] 以上所述,仅为本发明较佳的具体实施方式,但本发明的保护范围并不局限于此,任何熟悉本技术领域的技术人员在本发明揭露的技术范围内,根据本发明的技术方案及其

发明构思加以等同替换或改变,都应涵盖在本发明的保护范围之内。




图1




图2