



(12) 发明专利

(10) 授权公告号 CN 119167938 B

(45) 授权公告日 2025. 05. 02

(21) 申请号 202411393643.7

G06F 40/242 (2020.01)

(22) 申请日 2024.10.08

G16H 50/70 (2018.01)

(65) 同一申请的已公布的文献号

G06N 3/045 (2023.01)

申请公布号 CN 119167938 A

G06N 3/08 (2023.01)

(43) 申请公布日 2024.12.20

(56) 对比文件

CN 115879546 A, 2023.03.31

(73) 专利权人 广西警察学院

审查员 曹敏

地址 530028 广西壮族自治区南宁市青秀区
区长湖路6号

(72) 发明人 秦振凯 向秋焱 周胜 徐铭朝
梁家权 朱锋

(74) 专利代理机构 江苏昌禾律师事务所 32837
专利代理师 潘天志

(51) Int. Cl.

G06F 40/295 (2020.01)

G06F 40/30 (2020.01)


权利要求书5页 说明书12页 附图2页

(54) 发明名称

一种基于深度学习的医疗实体识别与关系抽取方法

(57) 摘要

本发明公开了一种基于深度学习的医疗实体识别与关系抽取方法, S1、获取并预处理医疗文本数据集; S2、构建医疗领域的词嵌入模型; S3、基于所述词嵌入模型, 构建并训练采用Attention机制的多层神经网络模型; S4、将经过训练的多层神经网络模型应用于新的医疗文本数据集, 对医疗文本数据集中的实体进行识别和分类; S5、在识别出实体后, 使用双向Attention机制对医疗文本数据集中的实体进行关系抽取; S6、针对不同类型的关系, 使用双向Attention机制分别进行处理; S7、结合医疗领域知识库, 对识别出的实体和关系进行验证与补充; S8、将最终识别和抽取的医疗实体及其关系以结构化形式输出。本发明提升了医疗文本分析的可靠性和实用性。



1.一种基于深度学习的医疗实体识别与关系抽取方法,其特征在于,包括如下步骤:

S1、获取并预处理医疗文本数据集,对医疗文本数据集进行分词、去停用词及标准化处理;

S2、构建医疗领域的词嵌入模型,利用医疗领域的术语词典和语料库对词嵌入模型进行训练,使词嵌入模型生成医疗术语的高维向量表示;

S3、基于所述词嵌入模型,构建并训练采用Attention机制的多层神经网络模型;

S4、将经过训练的多层神经网络模型应用于新的医疗文本数据集,对医疗文本数据集中的实体进行识别和分类;

S5、在识别出实体后,使用双向Attention机制对医疗文本数据集中的实体进行关系抽取,关系抽取包括识别实体之间的直接关系及通过上下文感知推断的潜在关联关系;

S6、针对不同类型的关系,使用双向Attention机制分别进行处理;

S7、结合医疗领域知识库,对识别出的实体和关系进行验证与补充;

S8、将最终识别和抽取的医疗实体及其关系以结构化形式输出;

所述S7具体包括:

S71、将识别出的实体集合 $E = \{e_1, e_2, \dots, e_n\}$ 和实体关系集合 $R = \{r_1, r_2, \dots, r_m\}$ 与医疗领域知识库 K_{med} 进行匹配,知识库 K_{med} 包括标准医学术语、疾病分类编码和药物数据库,定义实体匹配评分 $S_{match}(e_i)$:

$$S_{match}(e_i) = \frac{\sum_{k=1}^l \delta(e_i, K_k)}{\sqrt{l}};$$

其中, K_k 为知识库中的第k条医学术语或实体记录, $\delta(e_i, K_k)$ 为二值函数,当实体 e_i 与知识库中的实体 K_k 匹配时, $\delta(e_i, K_k) = 1$,否则为0,1为知识库中与实体 e_i 匹配的条目总数;

S72、根据实体匹配评分 $S_{match}(e_i)$ 对低匹配的实体 e_i 进行补充验证,从知识库 K_{med} 中检索与其语义相近的实体,计算实体相似度评分 $S_{sim}(e_i, K_k)$:

$$S_{sim}(e_i, K_k) = \cos(v_{e_i}, v_{K_k});$$

其中, v_{e_i} 和 v_{K_k} 分别为实体 e_i 和知识库中实体 K_k 的词向量表示, $\cos$ 表示词向量间的余弦相似度;

S73、针对识别出的关系集合 R 计算每对实体关系 $r_j = (e_i, e_k)$ 的关系匹配评分 $S_{match}(r_j)$:

$$S_{match}(r_j) = \lambda_6 \cdot \text{Rel}_{med}(e_i, e_k);$$

其中, $\text{Rel}_{med}(e_i, e_k)$ 为医疗知识库中与实体 e_i 和实体 e_k 之间关系的向量表示, λ_6 为调节系数,控制知识库对关系验证的影响;

S74、结合上下文感知生成的最终关系预测值 R_{ij} 与关系匹配评分 $S_{match}(r_j)$ 进行对比,当最终关系预测值 R_{ij} 与匹配评分之间的差异超过预设阈值时,使用知识库中的语义信息进行关系验证与补充;

S75、输出经过知识库验证和补充后的医疗实体集合和医疗关系集合:

$$E^* = \{e_1^*, e_2^*, \dots, e_n^*\};$$

$$R^* = \{r_1^*, r_2^*, \dots, r_m^*\};$$

其中, e_i^* 和 r_j^* 为经过验证补充后的医疗实体与医疗关系。

2. 根据权利要求1所述的一种基于深度学习的医疗实体识别与关系抽取方法, 其特征在于, 所述S1具体包括:

S11、获取医疗文本数据集:

$$D = \{d_1, d_2, \dots, d_n\};$$

其中, d_i 表示第 i 个医疗文本, n 为医疗文本的总数;

S12、使用分词算法对医疗文本数据集 D 进行分词处理, 将每个医疗文本 d_i 表示为词序列:

$$W_i = \{w_{i1}, w_{i2}, \dots, w_{im}\};$$

其中, w_{ij} 为第 i 个医疗文本中的第 j 个词, m 为医疗文本 d_i 中词的总数;

S13、去除停用词将每个词序列 W_i 中的停用词集合 S 过滤掉, 得到新的词序列 W'_i ;

S14、对去停用词后的词序列 W'_i 进行标准化处理, 转换大小写, 使所有词转为小写形式, 将词序列中的词还原为词干形式 W''_i ;

S15、将预处理后的医疗文本数据集表示为:

$$D' = \{W''_1, W''_2, \dots, W''_n\};$$

其中, W''_i 为第 i 个预处理后的词干化词序列。

3. 根据权利要求1所述的一种基于深度学习的医疗实体识别与关系抽取方法, 其特征在于, 所述S2具体包括:

S21、获取医疗领域的术语词典:

$$V = \{v_1, v_2, \dots, v_t\};$$

其中, v_i 表示第 i 个医疗术语, t 为术语词典中的术语总数;

S22、收集医疗领域的语料库:

$$C = \{c_1, c_2, \dots, c_p\};$$

其中 c_j 表示第 j 个医疗领域的文本片段, p 为语料库中文本片段的总数;

S23、基于所述医疗领域的术语词典 V 和医疗领域的语料库 C 构建医疗领域的词嵌入模型, 定义词嵌入模型的共现矩阵 $M(i, j)$ 为:

$$M(i, j) = \sum_{k=1}^p \sum_{l=1}^{q_k} f(v_i, e_{kl}) \cdot g(v_j, e_{kl+1}) \cdot h(c_k);$$

其中, $f(v_i, e_{kl})$ 表示术语 v_i 在第 k 个文本片段中与实体 e_{kl} 的关联程度, $g(v_j, e_{kl+1})$ 表示术语 v_j 与紧邻实体 e_{kl+1} 的关联度, $h(c_k)$ 为片段的权重因子, 代表该片段在整体语料库中的重要性, q_k 为文本片段 c_k 中的实体数量;

S24、采用医疗领域的上下文感知模型对共现矩阵 $M(i, j)$ 进行词向量训练, 定义词向量更新为:

$$v_i^{(t+1)} = v_i^{(t)} + \eta \cdot \sum_{j=1}^t \frac{M(i, j)}{\sqrt{\sum_{k=1}^t M(i, k)^2}} \cdot v_j^{(t)} + \lambda \cdot \sum_{m=1}^t E_m^{(t)};$$

其中, $v_i^{(t)}$ 表示第 i 个术语在第 t 次迭代的向量表示, η 为学习率, λ 为正则化项, $E_m^{(t)}$ 表示

医疗实体的词嵌入值;

S25、利用医疗领域的标准知识库优化词向量将词向量与标准编码映射,得到优化后的词向量 v_i^* :

$$v_i^* = v_i + \alpha \cdot \sum_{k=1}^Z \delta(WSK_k, v_i) \cdot WSK_k;$$

其中, α 为调整权重, $\delta(WSK_k, v_i)$ 表示医疗术语 v_i 与卫生部疾病分类编码标准 WSK 中的编码 WSK_k 之间的匹配程度, WSK_k 为对应 WSK 编码的向量表示;

S26、输出优化后的词嵌入模型:

$$E = \{v_1^*, v_2^*, \dots, v_t^*\};$$

其中, 每个 v_i^* 为经过优化后的医疗术语高维向量。

4. 根据权利要求1所述的一种基于深度学习的医疗实体识别与关系抽取方法, 其特征在于, 所述S3具体包括:

S31、接收预处理后的医疗文本数据集 D' , 输入层通过词嵌入模型将医疗文本数据集映射为高维向量序列 $X_i = \{x_{i1}, x_{i2}, \dots, x_{ik}\}$;

S32、通过全局Attention机制对输入的词向量序列 X_i 进行上下文感知处理, 计算注意力权重 α_{ij} , 注意力权重由词向量的相似度和医学术语的语义关联决定:

$$\alpha_{ij} = \frac{\exp\left(\frac{q_i \cdot k_j + \lambda_1 \cdot K_{med}(v_i, v_j)}{\sqrt{d_k}}\right)}{\sum_{i=1}^k \exp\left(\frac{q_i \cdot k_j + \lambda_1 \cdot K_{med}(v_i, v_j)}{\sqrt{d_k}}\right)};$$

其中, q_i 和 k_j 分别为查询向量和键向量, $K_{med}(v_i, v_j)$ 表示医学术语之间的领域知识关联, λ_1 为控制领域知识的重要性因子, d_k 为键向量的维度;

S33、通过注意力权重 α_{ij} 对输入向量 X_i 进行加权求和, 生成包括词序列中局部上下文信息和医学术语全局语义关联的上下文感知向量 h_i :

$$h_i = \sum_{j=1}^k \alpha_{ij} x_{ij} + \lambda_2 \cdot \sum_{p=1}^n K_{global}(v_{ip}, x_{ij});$$

其中, $K_{global}(v_{ip}, x_{ij})$ 表示全局医学知识库对词向量的上下文影响, λ_2 为控制全局医学知识的重要性因子;

S34、采用双向长短期记忆网络处理上下文感知向量 h_i , 前向和后向长短期记忆网络分别捕捉序列中上下文信息, 隐藏层的特征提取为:

$$h_i^{BiLSTM} = [\vec{LSTM}(h_i, W_f) + \sum_{m=1}^d \frac{g_{med}^{fw}(v_{im})}{\sqrt{d_f}}, \overleftarrow{LSTM}(h_i, W_b) + \sum_{n=1}^d \frac{g_{med}^{bw}(v_{in})}{\sqrt{d_b}}];$$

其中, $\vec{LSTM}$ 和 $\overleftarrow{LSTM}$ 分别为前向和后向长短期记忆网络, $g_{med}^{fw}(v_{im})$ 和 $g_{med}^{bw}(v_{in})$ 分别为前向和后向的医学术语影响因子, W_f 和 W_b 为LSTM的权重矩阵, d_f 和 d_b 为前向和后向的长短期记忆网络维度。

5. 根据权利要求1所述的一种基于深度学习的医疗实体识别与关系抽取方法, 其特征在于, 所述S5具体包括:

S51、在识别出实体后构建双向Attention机制, 双向Attention机制对识别出的实体进行关系抽取, 为每对识别出的实体 (e_i, e_j) 计算基于上下文的关联权重, 定义双向注意力权

重 α_{ij}^{fw} 和 α_{ij}^{bw} 分别表示前向和后向注意力权重:

$$\alpha_{ij}^{fw} = \frac{\exp(s_{ij}^{fw})}{\sum_{l=1}^n \exp(s_{il}^{fw})};$$

$$\alpha_{ij}^{bw} = \frac{\exp(s_{ij}^{bw})}{\sum_{l=1}^n \exp(s_{il}^{bw})};$$

其中, $s_{ij}^{fw} = q_i \cdot k_j^{fw}$ 和 $s_{ij}^{bw} = q_i \cdot k_j^{bw}$ 分别表示前向和后向的注意力评分, q_i 为实体 e_i 的查询向量, k_j^{fw} 和 k_j^{bw} 分别为实体 e_j 的前向和后向键向量;

S52、基于前向和后向注意力权重 α_{ij}^{fw} 和 α_{ij}^{bw} 计算实体 e_i 和 e_j 之间的上下文感知关系向量 r_{ij} :

$$r_{ij} = \alpha_{ij}^{fw} \cdot v_j^{fw} + \alpha_{ij}^{bw} \cdot v_j^{bw};$$

其中, v_j^{fw} 和 v_j^{bw} 分别表示实体 e_j 在前向和后向的上下文特征向量, r_{ij} 为两实体之间的关系向量;

S53、在计算完实体的直接关系后,利用上下文感知机制推断潜在关联关系基于识别出的实体和上下文关系,使用全局医学知识库 K_{global} 作为额外信息,定义潜在关联关系权重 β_{ij} :

$$\beta_{ij} = \lambda_5 \cdot K_{global}(e_i, e_j);$$

其中, λ_5 为控制全局医学知识库影响的权重因子, $K_{global}(e_i, e_j)$ 表示实体 e_i 和 e_j 在全局医学知识库中的关联程度;

S54、基于上下文感知的直接关系 r_{ij} 与潜在关联关系权重 β_{ij} ,计算实体之间的最终关系预测值 R_{ij} :

$$R_{ij} = r_{ij} + \beta_{ij};$$

其中, R_{ij} 为实体 e_i 和 e_j 之间的最终关系表示。

6.根据权利要求1所述的一种基于深度学习的医疗实体识别与关系抽取方法,其特征在于,所述S73具体包括:

S731、针对识别出的每对实体关系 $r_j = (e_i, e_k)$ 从医疗领域知识库 K_{med} 中提取实体 e_i 与实体 e_k 之间的关系向量表示 $Rel_{med}(e_i, e_k)$:

$$Rel_{med}(e_i, e_k) = [rel_1(e_i, e_k), rel_2(e_i, e_k), \dots, rel_n(e_i, e_k)];$$

其中, $rel_n(e_i, e_k)$ 表示实体 e_i 与实体 e_k 在知识库中的第n种关系属性, $Rel_{med}(e_i, e_k)$ 为汇总所有关系属性的向量表示;

S732、基于知识库提取的关系向量 $Rel_{med}(e_i, e_k)$ 与已识别实体关系 $r_j = (e_i, e_k)$ 进行匹配,计算用于衡量知识库中的关系与识别出的关系的一致性的关系匹配评分 $S_{match}(r_j)$:

$$S_{match}(r_j) = \lambda_6 \cdot \sum_{n=1}^N \frac{Rel_{med}(e_i, e_k) \cdot R_{ij}^{(n)}}{\|Rel_{med}(e_i, e_k)\| \|R_{ij}^{(n)}\|};$$

其中, $R_{ij}^{(n)}$ 表示通过上下文感知生成的第n种关系向量, λ_6 为调节系数,控制知识库对关系验证的影响,N为知识库中关系向量的总数, $\| \cdot \|$ 表示向量的范数,评分结果为两个向

量之间的余弦相似度；

S733、将关系匹配评分 $S_{\text{match}}(r_j)$ 与预设的匹配阈值进行对比,若 $S_{\text{match}}(r_j)$ 低于设定阈值,则重新从知识库中检索相关的实体关系信息,并对关系 r_j 进行验证与补充。

一种基于深度学习的医疗实体识别与关系抽取方法

技术领域

[0001] 本发明涉及医疗技术领域,尤其涉及一种基于深度学习的医疗实体识别与关系抽取方法。

背景技术

[0002] 现有技术中,医疗文本的实体识别与关系抽取主要依赖于传统的自然语言处理技术和基于规则的方法,但是传统的方法通常通过定义固定的规则或使用简单的统计模型来从医疗文本中识别出特定的医学实体,如疾病名称、药物和症状,并对实体之间的关系进行抽取,传统方法在面对复杂的医疗文本时,存在显著的局限性,医疗文本的专业性和复杂性导致了实体识别的困难,许多医学术语具有多义性或依赖于上下文,常见的NLP技术在处理这些术语时容易出现错误此外,医疗文本中大量使用的缩写和术语变化加剧了识别难度,导致识别率低、误分类率高。

[0003] 在关系抽取方面,传统的基于规则的方法通常只能够处理简单的实体关系,如“药物-治疗疾病”或“疾病-引发症状”的基本对应关系,这类方法在处理多层次的语义关联和复杂关系时显得力不从心,无法准确提取复杂的因果关系、时间顺序关系,随着医疗数据量的增加和文本结构的复杂化,传统方法的局限性愈加明显,此外,现有技术依赖于固定规则,无法根据数据的动态变化进行自我优化和学习,限制了系统在实际应用场景中的适应性。

[0004] 此外,虽然部分现有技术尝试引入机器学习算法来改进实体识别和关系抽取的性能,但机器学习算法通常依赖于大规模的标注数据,然而,医疗领域的标注数据获取困难且标注成本高,导致模型难以在实际应用中有效推广,此外,现有的机器学习模型通常难以与医疗领域的知识库进行深度结合,无法充分利用医学领域的专业知识进行实体识别与关系抽取,从而影响了整体模型的准确性和实用性。

发明内容

[0005] 本发明的一个目的在于提出一种基于深度学习的医疗实体识别与关系抽取方法,本发明提升了医疗文本分析的可靠性和实用性。

[0006] 根据本发明实施例的一种基于深度学习的医疗实体识别与关系抽取方法,包括如下步骤:

[0007] S1、获取并预处理医疗文本数据集,对医疗文本数据集进行分词、去停用词及标准化处理;

[0008] S2、构建医疗领域的词嵌入模型,利用医疗领域的术语词典和语料库对词嵌入模型进行训练,使词嵌入模型生成医疗术语的高维向量表示;

[0009] S3、基于所述词嵌入模型,构建并训练采用Attention机制的多层神经网络模型;

[0010] S4、将经过训练的多层神经网络模型应用于新的医疗文本数据集,对医疗文本数据集中的实体进行识别和分类;

[0011] S5、在识别出实体后,使用双向Attention机制对医疗文本数据集中的实体进行关系抽取,关系抽取包括识别实体之间的直接关系及通过上下文感知推断的潜在关联关系;

[0012] S6、针对不同类型的关系,使用双向Attention机制分别进行处理;

[0013] S7、结合医疗领域知识库,对识别出的实体和关系进行验证与补充;

[0014] S8、将最终识别和抽取的医疗实体及其关系以结构化形式输出。

[0015] 可选的,所述S1具体包括:

[0016] S11、获取医疗文本数据集:

[0017] $D = \{d_1, d_2, \dots, d_n\}$;

[0018] 其中, d_i 表示第*i*个医疗文本, n 为医疗文本的总数;

[0019] S12、使用分词算法对医疗文本数据集*D*进行分词处理,将每个医疗文本 d_i 表示为词序列:

[0020] $W_i = \{w_{i1}, w_{i2}, \dots, w_{im}\}$;

[0021] 其中, w_{ij} 为第*i*个医疗文本中的第*j*个词, m 为医疗文本 d_i 中词的总数;

[0022] S13、去除停用词将每个词序列 W_i 中的停用词集合*S*过滤掉,得到新的词序列 W'_i ;

[0023] S14、对去停用词后的词序列 W'_i 进行标准化处理,转换大小写,使所有词转为小写形式,将词序列中的词还原为词干形式 W''_i ;

[0024] S15、将预处理后的医疗文本数据集表示为:

[0025] $D' = \{W''_1, W''_2, \dots, W''_n\}$;

[0026] 其中, W''_i 为第*i*个预处理后的词干化词序列。

[0027] 可选的,所述S2具体包括:

[0028] S21、获取医疗领域的术语词典:

[0029] $V = \{v_1, v_2, \dots, v_t\}$;

[0030] 其中, v_i 表示第*i*个医疗术语, t 为术语词典中的术语总数;

[0031] S22、收集医疗领域的语料库:

[0032] $C = \{c_1, c_2, \dots, c_p\}$;

[0033] 其中 c_j 表示第*j*个医疗领域的文本片段, p 为语料库中文本片段的总数;

[0034] S23、基于所述医疗领域的术语词典*V*和医疗领域的语料库*C*构建医疗领域的词嵌入模型,定义词嵌入模型的共现矩阵 $M(i, j)$ 为:

[0035] $M(i, j) = \sum_{k=1}^p \sum_{l=1}^{q_k} f(v_i, e_{kl}) \cdot g(v_j, e_{kl+1}) \cdot h(c_k);$

[0036] 其中, $f(v_i, e_{kl})$ 表示术语 v_i 在第*k*个文本片段中与实体 e_{kl} 的关联程度, $g(v_j, e_{kl+1})$ 表示术语 v_j 与紧邻实体 e_{kl+1} 的关联度, $h(c_k)$ 为片段的权重因子,代表该片段在整体语料库中的重要性, q_k 为文本片段 c_k 中的实体数量;

[0037] S24、采用医疗领域的上下文感知模型对共现矩阵 $M(i, j)$ 进行词向量训练,定义词向量更新为:

[0038]
$$v_i^{(t+1)} = v_i^{(t)} + \eta \cdot \sum_{j=1}^t \frac{M(i, j)}{\sqrt{\sum_{k=1}^t M(i, k)^2}} \cdot v_j^{(t)} + \lambda \cdot \sum_{m=1}^t E_m^{(t)};$$

[0039] 其中, $v_i^{(t)}$ 表示第 i 个术语在第 t 次迭代的向量表示, η 为学习率, λ 为正则化项, $E_m^{(t)}$ 表示医疗实体的词嵌入值;

[0040] S25、利用医疗领域的标准知识库优化词向量将词向量与标准编码映射, 得到优化后的词向量 v_i^* :

$$[0041] \quad v_i^* = v_i + \alpha \cdot \sum_{k=1}^z \delta(\text{WSK}_k, v_i) \cdot \text{WSK}_k;$$

[0042] 其中, α 为调整权重, $\delta(\text{WSK}_k, v_i)$ 表示医疗术语 v_i 与卫生部疾病分类编码标准 WSK 中的编码 WSK_k 之间的匹配程度, WSK_k 为对应 WSK 编码的向量表示;

[0043] S26、输出优化后的词嵌入模型:

$$[0044] \quad E = \{v_1^*, v_2^*, \dots, v_t^*\};$$

[0045] 其中, 每个 v_i^* 为经过优化后的医疗术语高维向量。

[0046] 可选的, 所述 S3 具体包括:

[0047] S31、接收预处理后的医疗文本数据集 D' , 输入层通过词嵌入模型将医疗文本数据集映射为高维向量序列 $X_i = \{x_{i1}, x_{i2}, \dots, x_{ik}\}$;

[0048] S32、通过全局 Attention 机制对输入的词向量序列 X_i 进行上下文感知处理, 计算注意力权重 α_{ij} , 注意力权重由词向量的相似度和医学术语的语义关联决定:

$$[0049] \quad \alpha_{ij} = \frac{\exp\left(\frac{q_i \cdot k_j + \lambda_1 \cdot K_{\text{med}}(v_i, v_j)}{\sqrt{d_k}}\right)}{\sum_{j=1}^k \exp\left(\frac{q_i \cdot k_j + \lambda_1 \cdot K_{\text{med}}(v_i, v_j)}{\sqrt{d_k}}\right)};$$

[0050] 其中, q_i 和 k_j 分别为查询向量和键向量, $K_{\text{med}}(v_i, v_j)$ 表示医学术语之间的领域知识关联, λ_1 为控制领域知识的重要性因子, d_k 为键向量的维度;

[0051] S33、通过注意力权重 α_{ij} 对输入向量 X_i 进行加权求和, 生成包括词序列中局部上下文信息和医学术语全局语义关联的上下文感知向量 h_i :

$$[0052] \quad h_i = \sum_{j=1}^k \alpha_{ij} x_{ij} + \lambda_2 \cdot \sum_{p=1}^n K_{\text{global}}(v_{ip}, x_{ij});$$

[0053] 其中, $K_{\text{global}}(v_{ip}, x_{ij})$ 表示全局医学知识库对词向量的上下文影响, λ_2 为控制全局医学知识的重要性因子;

[0054] S34、采用双向长短期记忆网络处理上下文感知向量 h_i , 前向和后向长短期记忆网络分别捕捉序列中上下文信息, 隐藏层的特征提取为:

$$[0055] \quad h_i^{\text{BiLSTM}} = [\vec{\text{LSTM}}(h_i, W_f) + \sum_{m=1}^d \frac{g_{\text{med}}^{\text{fw}}(v_{im})}{\sqrt{d_f}}, \overleftarrow{\text{LSTM}}(h_i, W_b) + \sum_{n=1}^d \frac{g_{\text{med}}^{\text{bw}}(v_{in})}{\sqrt{d_b}}];$$

[0056] 其中, $\vec{\text{LSTM}}$ 和 $\overleftarrow{\text{LSTM}}$ 分别为前向和后向长短期记忆网络, $g_{\text{med}}^{\text{fw}}(v_{im})$ 和 $g_{\text{med}}^{\text{bw}}(v_{in})$ 分别为前向和后向的医学术语影响因子, W_f 和 W_b 为 LSTM 的权重矩阵, d_f 和 d_b 为前向和后向的长短期记忆网络维度。

[0057] 可选的, 所述 S5 具体包括:

[0058] S51、在识别出实体后构建双向 Attention 机制, 双向 Attention 机制对识别出的实体进行关系抽取, 为每对识别出的实体 (e_i, e_j) 计算基于上下文的关联权重, 定义双向注意

力权重 α_{ij}^{fw} 和 α_{ij}^{bw} 分别表示前向和后向注意力权重:

$$[0059] \quad \alpha_{ij}^{fw} = \frac{\exp(s_{ij}^{fw})}{\sum_{l=1}^n \exp(s_{il}^{fw})};$$

$$[0060] \quad \alpha_{ij}^{bw} = \frac{\exp(s_{ij}^{bw})}{\sum_{l=1}^n \exp(s_{il}^{bw})};$$

[0061] 其中, $s_{ij}^{fw} = q_i \cdot k_j^{fw}$ 和 $s_{ij}^{bw} = q_i \cdot k_j^{bw}$ 分别表示前向和后向的注意力评分, q_i 为实体 e_i 的查询向量, k_j^{fw} 和 k_j^{bw} 分别为实体 e_j 的前向和后向键向量;

[0062] S52、基于前向和后向注意力权重 α_{ij}^{fw} 和 α_{ij}^{bw} 计算实体 e_i 和 e_j 之间的上下文感知关系向量 r_{ij} :

$$[0063] \quad r_{ij} = \alpha_{ij}^{fw} \cdot v_j^{fw} + \alpha_{ij}^{bw} \cdot v_j^{bw};$$

[0064] 其中, v_j^{fw} 和 v_j^{bw} 分别表示实体 e_j 在前向和后向的上下文特征向量, r_{ij} 为两实体之间的关系向量;

[0065] S53、在计算完实体的直接关系后,利用上下文感知机制推断潜在关联关系基于识别出的实体和上下文关系,使用全局医学知识库 K_{global} 作为额外信息,定义潜在关联关系权重 β_{ij} :

$$[0066] \quad \beta_{ij} = \lambda_5 \cdot K_{global}(e_i, e_j);$$

[0067] 其中, λ_5 为控制全局医学知识库影响的权重因子, $K_{global}(e_i, e_j)$ 表示实体 e_i 和 e_j 在全局医学知识库中的关联程度;

[0068] S54、基于上下文感知的直接关系 r_{ij} 与潜在关联关系权重 β_{ij} ,计算实体之间的最终关系预测值 R_{ij} :

$$[0069] \quad R_{ij} = r_{ij} + \beta_{ij};$$

[0070] 其中, R_{ij} 为实体 e_i 和 e_j 之间的最终关系表示。

[0071] 可选的,所述S7具体包括:

[0072] S71、将识别出的实体集合 $E = \{e_1, e_2, \dots, e_n\}$ 和实体关系集合 $R = \{r_1, r_2, \dots, r_m\}$ 与医疗领域知识库 K_{med} 进行匹配,知识库 K_{med} 包括标准医学术语、疾病分类编码和药物数据库,定义实体匹配评分 $S_{match}(e_i)$:

$$[0073] \quad S_{match}(e_i) = \frac{\sum_{k=1}^l \delta(e_i, K_k)}{\sqrt{l}};$$

[0074] 其中, K_k 为知识库中的第 k 条医学术语或实体记录, $\delta(e_i, K_k)$ 为二值函数,当实体 e_i 与知识库中的实体 K_k 匹配时, $\delta(e_i, K_k) = 1$, 否则为 0, l 为知识库中与实体 e_i 匹配的条目总数;

[0075] S72、根据实体匹配评分 $S_{match}(e_i)$ 对低匹配的实体 e_i 进行补充验证,从知识库 K_{med} 中检索与其语义相近的实体,计算实体相似度评分 $S_{sim}(e_i, K_k)$:

$$[0076] \quad S_{sim}(e_i, K_k) = \cos(v_{e_i}, v_{K_k});$$

[0077] 其中, v_{e_i} 和 v_{K_k} 分别为实体 e_i 和知识库中实体 K_k 的词向量表示, $\cos$ 表示词向量间的余弦相似度;

[0078] S73、针对识别出的关系集合R计算每对实体关系 $r_j = (e_i, e_k)$ 的关系匹配评分 $S_{match}(r_j)$ ：

[0079] $S_{match}(r_j) = \lambda_6 \cdot \text{Rel}_{med}(e_i, e_k)$ ；

[0080] 其中， $\text{Rel}_{med}(e_i, e_k)$ 为医疗知识库中与实体 e_i 和实体 e_k 之间关系的向量表示， λ_6 为调节系数，控制知识库对关系验证的影响；

[0081] S74、结合上下文感知生成的最终关系预测值 R_{ij} 与关系匹配评分 $S_{match}(r_j)$ 进行对比，当最终关系预测值 R_{ij} 与匹配评分之间的差异超过预设阈值时，使用知识库中的语义信息进行关系验证与补充；

[0082] S75、输出经过知识库验证和补充后的医疗实体集合和医疗关系集合：

[0083] $E^* = \{e_1^*, e_2^*, \dots, e_n^*\}$ ；

[0084] $R^* = \{r_1^*, r_2^*, \dots, r_m^*\}$ ；

[0085] 其中， e_i^* 和 r_j^* 为经过验证补充后的医疗实体与医疗关系。

[0086] 可选的，所述S73具体包括：

[0087] S731、针对识别出的每对实体关系 $r_j = (e_i, e_k)$ 从医疗领域知识库 K_{med} 中提取实体 e_i 与实体 e_k 之间的关系向量表示 $\text{Rel}_{med}(e_i, e_k)$ ：

[0088] $\text{Rel}_{med}(e_i, e_k) = [\text{rel}_1(e_i, e_k), \text{rel}_2(e_i, e_k), \dots, \text{rel}_n(e_i, e_k)]$ ；

[0089] 其中， $\text{rel}_n(e_i, e_k)$ 表示实体 e_i 与实体 e_k 在知识库中的第n种关系属性， $\text{Rel}_{med}(e_i, e_k)$ 为汇总所有关系属性的向量表示；

[0090] S732、基于知识库提取的关系向量 $\text{Rel}_{med}(e_i, e_k)$ 与已识别实体关系 $r_j = (e_i, e_k)$ 进行匹配，计算用于衡量知识库中的关系与识别出的关系的一致性的关系匹配评分 $S_{match}(r_j)$ ：

$$[0091] \quad S_{match}(r_j) = \lambda_6 \cdot \sum_{n=1}^N \frac{\text{Rel}_{med}(e_i, e_k) \cdot R_{ij}^{(n)}}{\|\text{Rel}_{med}(e_i, e_k)\| \|R_{ij}^{(n)}\|} ;$$

[0092] 其中， $R_{ij}^{(n)}$ 表示通过上下文感知生成的第n种关系向量， λ_6 为调节系数，控制知识库对关系验证的影响，N为知识库中关系向量的总数， $\| \cdot \|$ 表示向量的范数，评分结果为两个向量之间的余弦相似度；

[0093] S733、将关系匹配评分 $S_{match}(r_j)$ 与预设的匹配阈值进行对比，若 $S_{match}(r_j)$ 低于设定阈值，则重新从知识库中检索相关的实体关系信息，并对关系 r_j 进行验证与补充。

[0094] 本发明的有益效果是：

[0095] (1) 本发明通过引入基于医疗领域优化的词嵌入模型，结合医疗术语的专业词典与语料库训练模型，显著提升了实体识别的准确性，利用Attention机制捕捉医疗术语及其语境信息，词嵌入模型有效处理医学文本中的多义词和缩写问题，解决了传统NLP模型在面对专业医学术语时容易发生的误分类与漏识别问题，同时，结合双向长短期记忆网络，模型能够捕获文本中的上下文信息，从而进一步增强了实体识别的语义理解能力，使识别结果更加精确。

[0096] (2) 本发明提出了基于双向Attention机制和上下文感知的关系抽取方法，能够自动识别并推断出医疗文本中复杂的实体关系，通过全局与局部的Attention机制相结合，不

仅能识别实体之间的直接关系,还能通过上下文信息推断出隐含的潜在关系,结合医疗领域知识库中的关系向量,模型在抽取复杂语义关联时能够自动进行验证与补充,有效解决了现有技术在处理多层次语义关系时信息丢失的难题,大幅提升了模型在复杂场景下的关系抽取能力。

[0097] (3) 本发明通过引入医疗领域知识库对识别出的实体和关系进行自动验证与补充,解决了现有技术中无法充分利用医疗领域知识的问题,通过匹配评分和相似度计算,系统能够动态调整低匹配实体和关系的识别结果,结合领域知识进行有效的补充验证,保证了实体和关系的准确性,通过知识库的交叉验证机制,模型可以自动修正识别中的误差,减少了由于数据缺失或语义模糊带来的错误识别,进一步提升医疗文本分析的可靠性和实用性。

附图说明

[0098] 附图用来提供对本发明的进一步理解,并且构成说明书的一部分,与本发明的实施例一起用于解释本发明,并不构成对本发明的限制。在附图中:

[0099] 图1为本发明提出的一种基于深度学习的医疗实体识别与关系抽取方法的流程图;

[0100] 图2为本发明提出的一种基于深度学习的医疗实体识别与关系抽取方法中使用的双向Attention机制的详细示意图。

具体实施方式

[0101] 现在结合附图对本发明作进一步详细的说明。这些附图均为简化的示意图,仅以示意方式说明本发明的基本结构,因此其仅显示与本发明有关的构成。

[0102] 参考图1-2,一种基于深度学习的医疗实体识别与关系抽取方法,包括如下步骤:

[0103] S1、获取并预处理医疗文本数据集,对医疗文本数据集进行分词、去停用词及标准化处理;

[0104] S2、构建医疗领域的词嵌入模型,利用医疗领域的术语词典和语料库对词嵌入模型进行训练,使词嵌入模型生成医疗术语的高维向量表示;

[0105] S3、基于词嵌入模型,构建并训练采用Attention机制的多层神经网络模型;

[0106] S4、将经过训练的多层神经网络模型应用于新的医疗文本数据集,对医疗文本数据集中的实体进行识别和分类;

[0107] S5、在识别出实体后,使用双向Attention机制对医疗文本数据集中的实体进行关系抽取,关系抽取包括识别实体之间的直接关系及通过上下文感知推断的潜在关联关系;

[0108] S6、针对不同类型的关系,使用双向Attention机制分别进行处理;

[0109] S7、结合医疗领域知识库,对识别出的实体和关系进行验证与补充;

[0110] S8、将最终识别和抽取的医疗实体及其关系以结构化形式输出。

[0111] 本实施方式中,S1具体包括:

[0112] S11、获取医疗文本数据集:

[0113] $D = \{d_1, d_2, \dots, d_n\}$;

[0114] 其中, d_i 表示第*i*个医疗文本,*n*为医疗文本的总数;

[0115] S12、使用分词算法对医疗文本数据集D进行分词处理,将每个医疗文本 d_i 表示为词序列:

[0116] $W_i = \{w_{i1}, w_{i2}, \dots, w_{im}\};$

[0117] 其中, w_{ij} 为第i个医疗文本中的第j个词,m为医疗文本 d_i 中词的总数;

[0118] S13、去除停用词将每个词序列 W_i 中的停用词集合S过滤掉,得到新的词序列 W'_i ;

[0119] S14、对去停用词后的词序列 W'_i 进行标准化处理,转换大小写,使所有词转为小写形式,将词序列中的词还原为词干形式 W''_i ;

[0120] S15、将预处理后的医疗文本数据集表示为:

[0121] $D' = \{W''_1, W''_2, \dots, W''_n\};$

[0122] 其中, W''_i 为第i个预处理后的词干化词序列。

[0123] 本实施方式中,S2具体包括:

[0124] S21、获取医疗领域的术语词典:

[0125] $V = \{v_1, v_2, \dots, v_t\};$

[0126] 其中, v_i 表示第i个医疗术语,t为术语词典中的术语总数;

[0127] S22、收集医疗领域的语料库:

[0128] $C = \{c_1, c_2, \dots, c_p\};$

[0129] 其中 c_j 表示第j个医疗领域的文本片段,p为语料库中文本片段的总数;

[0130] S23、基于医疗领域的术语词典V和医疗领域的语料库C构建医疗领域的词嵌入模型,定义词嵌入模型的共现矩阵 $M(i, j)$ 为:

[0131] $M(i, j) = \sum_{k=1}^p \sum_{l=1}^{q_k} f(v_i, e_{kl}) \cdot g(v_j, e_{kl+1}) \cdot h(c_k);$

[0132] 其中, $f(v_i, e_{kl})$ 表示术语 v_i 在第k个文本片段中与实体 e_{kl} 的关联程度, $g(v_j, e_{kl+1})$ 表示术语 v_j 与紧邻实体 e_{kl+1} 的关联度, $h(c_k)$ 为片段的权重因子,代表该片段在整体语料库中的重要性, q_k 为文本片段 c_k 中的实体数量;

[0133] S24、采用医疗领域的上下文感知模型对共现矩阵 $M(i, j)$ 进行词向量训练,定义词向量更新为:

[0134]
$$v_i^{(t+1)} = v_i^{(t)} + \eta \cdot \sum_{j=1}^t \frac{M(i,j)}{\sqrt{\sum_{k=1}^t M(i,k)^2}} \cdot v_j^{(t)} + \lambda \cdot \sum_{m=1}^t E_m^{(t)};$$

[0135] 其中, $v_i^{(t)}$ 表示第i个术语在第t次迭代的向量表示, η 为学习率, λ 为正则化项, $E_m^{(t)}$ 表示医疗实体的词嵌入值;

[0136] S25、利用医疗领域的标准知识库优化词向量将词向量与标准编码映射,得到优化后的词向量 v_i^* :

[0137] $v_i^* = v_i + \alpha \cdot \sum_{k=1}^Z \delta(WSK_k, v_i) \cdot WSK_k;$

[0138] 其中, α 为调整权重, $\delta(WSK_k, v_i)$ 表示医疗术语 v_i 与卫生部疾病分类编码标准WSK中的编码 WSK_k 之间的匹配程度, WSK_k 为对应WSK编码的向量表示;

[0139] S26、输出优化后的词嵌入模型:

[0140] $E = \{v_1^*, v_2^*, \dots, v_t^*\};$

[0141] 其中,每个 v_i^* 为经过优化后的医疗术语高维向量。

[0142] 本实施方式中,S3具体包括:

[0143] S31、接收预处理后的医疗文本数据集 D' ,输入层通过词嵌入模型将医疗文本数据集映射为高维向量序列 $X_i = \{x_{i1}, x_{i2}, \dots, x_{ik}\};$

[0144] S32、通过全局Attention机制对输入的词向量序列 X_i 进行上下文感知处理,计算注意力权重 α_{ij} ,注意力权重由词向量的相似度和医学术语的语义关联决定:

$$[0145] \quad \alpha_{ij} = \frac{\exp\left(\frac{q_i \cdot k_j + \lambda_1 \cdot K_{med}(v_i, v_j)}{\sqrt{d_k}}\right)}{\sum_{l=1}^k \exp\left(\frac{q_i \cdot k_l + \lambda_1 \cdot K_{med}(v_i, v_l)}{\sqrt{d_k}}\right)};$$

[0146] 其中, q_i 和 k_j 分别为查询向量和键向量, $K_{med}(v_i, v_j)$ 表示医学术语之间的领域知识关联, λ_1 为控制领域知识的重要性因子, d_k 为键向量的维度;

[0147] S33、通过注意力权重 α_{ij} 对输入向量 X_i 进行加权求和,生成包括词序列中局部上下文信息和医学术语全局语义关联的上下文感知向量 h_i :

$$[0148] \quad h_i = \sum_{j=1}^k \alpha_{ij} x_{ij} + \lambda_2 \cdot \sum_{p=1}^n K_{global}(v_{ip}, x_{ij});$$

[0149] 其中, $K_{global}(v_{ip}, x_{ij})$ 表示全局医学知识库对词向量的上下文影响, λ_2 为控制全局医学知识的重要性因子;

[0150] S34、采用双向长短期记忆网络处理上下文感知向量 h_i ,前向和后向长短期记忆网络分别捕捉序列中上下文信息,隐藏层的特征提取为:

$$[0151] \quad h_i^{BiLSTM} = [LSTM(h_i, W_f) + \sum_{m=1}^d \frac{g_{med}^{fw}(v_{im})}{\sqrt{d_f}}, LSTM(h_i, W_b) + \sum_{n=1}^d \frac{g_{med}^{bw}(v_{in})}{\sqrt{d_b}}];$$

[0152] 其中, $\overrightarrow{LSTM}$ 和 $\overleftarrow{LSTM}$ 分别为前向和后向长短期记忆网络, $g_{med}^{fw}(v_{im})$ 和 $g_{med}^{bw}(v_{in})$ 分别为前向和后向的医学术语影响因子, W_f 和 W_b 为LSTM的权重矩阵, d_f 和 d_b 为前向和后向的长短期记忆网络维度。

[0153] 本实施方式中,S5具体包括:

[0154] S51、在识别出实体后构建双向Attention机制,双向Attention机制对识别出的实体进行关系抽取,为每对识别出的实体 (e_i, e_j) 计算基于上下文的关联权重,定义双向注意力权重 α_{ij}^{fw} 和 α_{ij}^{bw} 分别表示前向和后向注意力权重:

$$[0155] \quad \alpha_{ij}^{fw} = \frac{\exp(s_{ij}^{fw})}{\sum_{l=1}^n \exp(s_{il}^{fw})};$$

$$[0156] \quad \alpha_{ij}^{bw} = \frac{\exp(s_{ij}^{bw})}{\sum_{l=1}^n \exp(s_{il}^{bw})};$$

[0157] 其中, $s_{ij}^{fw} = q_i \cdot k_j^{fw}$ 和 $s_{ij}^{bw} = q_i \cdot k_j^{bw}$ 分别表示前向和后向的注意力评分, q_i 为实体 e_i 的查询向量, k_j^{fw} 和 k_j^{bw} 分别为实体 e_j 的前向和后向键向量;

[0158] S52、基于前向和后向注意力权重 α_{ij}^{fw} 和 α_{ij}^{bw} 计算实体 e_i 和 e_j 之间的上下文感知关系

向量 r_{ij} :

$$[0159] \quad r_{ij} = \alpha_{ij}^{fw} \cdot v_j^{fw} + \alpha_{ij}^{bw} \cdot v_j^{bw};$$

[0160] 其中, v_j^{fw} 和 v_j^{bw} 分别表示实体 e_j 在前向和后向的上下文特征向量, r_{ij} 为两实体之间的关系向量;

[0161] S53、在计算完实体的直接关系后,利用上下文感知机制推断潜在关联关系基于识别出的实体和上下文关系,使用全局医学知识库 K_{global} 作为额外信息,定义潜在关联关系权重 β_{ij} :

$$[0162] \quad \beta_{ij} = \lambda_5 \cdot K_{global}(e_i, e_j);$$

[0163] 其中, λ_5 为控制全局医学知识库影响的权重因子, $K_{global}(e_i, e_j)$ 表示实体 e_i 和 e_j 在全局医学知识库中的关联程度;

[0164] S54、基于上下文感知的直接关系 r_{ij} 与潜在关联关系权重 β_{ij} ,计算实体之间的最终关系预测值 R_{ij} :

$$[0165] \quad R_{ij} = r_{ij} + \beta_{ij};$$

[0166] 其中, R_{ij} 为实体 e_i 和 e_j 之间的最终关系表示。

[0167] 本实施方式中, S7具体包括:

[0168] S71、将识别出的实体集合 $E = \{e_1, e_2, \dots, e_n\}$ 和实体关系集合 $R = \{r_1, r_2, \dots, r_m\}$ 与医疗领域知识库 K_{med} 进行匹配,知识库 K_{med} 包括标准医学术语、疾病分类编码和药物数据库,定义实体匹配评分 $S_{match}(e_i)$:

$$[0169] \quad S_{match}(e_i) = \frac{\sum_{k=1}^l \delta(e_i, K_k)}{\sqrt{l}};$$

[0170] 其中, K_k 为知识库中的第 k 条医学术语或实体记录, $\delta(e_i, K_k)$ 为二值函数,当实体 e_i 与知识库中的实体 K_k 匹配时, $\delta(e_i, K_k) = 1$, 否则为0, l 为知识库中与实体 e_i 匹配的条目总数;

[0171] S72、根据实体匹配评分 $S_{match}(e_i)$ 对低匹配的实体 e_i 进行补充验证,从知识库 K_{med} 中检索与其语义相近的实体,计算实体相似度评分 $S_{sim}(e_i, K_k)$:

$$[0172] \quad S_{sim}(e_i, K_k) = \cos(v_{e_i}, v_{K_k});$$

[0173] 其中, v_{e_i} 和 v_{K_k} 分别为实体 e_i 和知识库中实体 K_k 的词向量表示, $\cos$ 表示词向量间的余弦相似度;

[0174] S73、针对识别出的关系集合 R 计算每对实体关系 $r_j = (e_i, e_k)$ 的关系匹配评分 $S_{match}(r_j)$:

$$[0175] \quad S_{match}(r_j) = \lambda_6 \cdot Rel_{med}(e_i, e_k);$$

[0176] 其中, $Rel_{med}(e_i, e_k)$ 为医疗知识库中与实体 e_i 和实体 e_k 之间关系的向量表示, λ_6 为调节系数,控制知识库对关系验证的影响;

[0177] S74、结合上下文感知生成的最终关系预测值 R_{ij} 与关系匹配评分 $S_{match}(r_j)$ 进行对比,当最终关系预测值 R_{ij} 与匹配评分之间的差异超过预设阈值时,使用知识库中的语义信息进行关系验证与补充;

[0178] S75、输出经过知识库验证和补充后的医疗实体集合和医疗关系集合:

$$[0179] \quad E^* = \{e_1^*, e_2^*, \dots, e_n^*\};$$

[0180] $R^* = \{r_1^*, r_2^*, \dots, r_m^*\};$

[0181] 其中, e_i^* 和 r_j^* 为经过验证补充后的医疗实体与医疗关系。

[0182] 本实施方式中, S73具体包括:

[0183] S731、针对识别出的每对实体关系 $r_j = (e_i, e_k)$ 从医疗领域知识库 K_{med} 中提取实体 e_i 与实体 e_k 之间的关系向量表示 $Rel_{med}(e_i, e_k)$:

[0184] $Rel_{med}(e_i, e_k) = [rel_1(e_i, e_k), rel_2(e_i, e_k), \dots, rel_n(e_i, e_k)];$

[0185] 其中, $rel_n(e_i, e_k)$ 表示实体 e_i 与实体 e_k 在知识库中的第 n 种关系属性, $Rel_{med}(e_i, e_k)$ 为汇总所有关系属性的向量表示;

[0186] S732、基于知识库提取的关系向量 $Rel_{med}(e_i, e_k)$ 与已识别实体关系 $r_j = (e_i, e_k)$ 进行匹配, 计算用于衡量知识库中的关系与识别出的关系的一致性的关系匹配评分 $S_{match}(r_j)$:

$$[0187] \quad S_{match}(r_j) = \lambda_6 \cdot \sum_{n=1}^N \frac{Rel_{med}(e_i, e_k) \cdot R_{ij}^{(n)}}{\|Rel_{med}(e_i, e_k)\| \|R_{ij}^{(n)}\|};$$

[0188] 其中, $R_{ij}^{(n)}$ 表示通过上下文感知生成的第 n 种关系向量, λ_6 为调节系数, 控制知识库对关系验证的影响, N 为知识库中关系向量的总数, $\| \cdot \|$ 表示向量的范数, 评分结果为两个向量之间的余弦相似度;

[0189] S733、将关系匹配评分 $S_{match}(r_j)$ 与预设的匹配阈值进行对比, 若 $S_{match}(r_j)$ 低于设定阈值, 则重新从知识库中检索相关的实体关系信息, 并对关系 r_j 进行验证与补充。

[0190] 实施例1:

[0191] 在2023年7月至2023年9月期间, 某大型三甲医院对其积累的大量历史病例数据进行了分析, 使用了本发明中的基于深度学习的医疗实体识别与关系抽取方法, 医院的目标是通过自动化技术提高其电子病历系统的效率, 减少医生在文本信息处理上的时间, 并提升诊断和治疗建议的准确性, 期间, 医院选取了1万份包含复杂医学信息的病例数据, 作为模型的训练和测试集。

[0192] 在7月15日的测试中, 一位患者的病例描述为: “患者因2型糖尿病服用二甲双胍, 血糖控制不佳, 伴随有视力模糊和体重减轻。” 传统的NLP模型在处理这类文本时, 虽然能够识别出“糖尿病”和“二甲双胍”两个实体, 但无法推断出视力模糊和体重减轻作为并发症的相关性, 导致提取的信息不完整, 然而, 本发明的方法通过其双向Attention机制, 结合上下文感知与医疗领域知识库, 准确地识别出“2型糖尿病”作为疾病实体、“二甲双胍”作为药物实体, 同时通过上下文推断, 自动关联了“视力模糊”和“体重减轻”作为并发症状。

[0193] 在此次测试中, 医院选取了5000份病例数据进行实体识别与关系抽取的测试, 并将本发明的方法与传统的规则基于NLP方法进行了对比实验, 实验数据具体如下:

[0194] 表1医疗实体识别与关系抽取方法对比

	方法	实体识别准确率	关系抽取准确率	并发症识别率	实体关系验证时间（每千份病例）
[0195]	本发明的方法	92.7%	90.4%	87.6%	35 分钟
	传统基于规则的方法	75.3%	68.9%	41.5%	90 分钟

[0196] 在实际案例中,系统通过实时处理病例数据集,成功识别出大量重要医疗实体,并推断出了多个复杂关系,实施例1中,8月2日的一份病例描述为:“患者长期服用阿司匹林,近期因胃溃疡复发停止用药。”传统方法只能识别出“阿司匹林”和“胃溃疡”两个实体,而本发明的方法能够通过上下文推断出“阿司匹林”作为导致“胃溃疡复发”的潜在诱因,并生成了“药物-症状”的复杂关联关系报告。

[0197] 8月10日,医院的一位医生在病例系统中检索了一位因高血压长期服用药物的患者,病例描述为:“患者服用氨氯地平,最近出现头痛和恶心症状。”传统的分析方法能够识别出“高血压”和“氨氯地平”这两个实体,但无法准确提取出“头痛”和“恶心”作为药物不良反应,本发明的方法通过基于深度学习的实体识别模型,不仅识别了“高血压”和“氨氯地平”之间的关系,还通过上下文感知推断出“头痛”和“恶心”可能与药物相关,经过医疗知识库验证,系统确认这些症状与“氨氯地平”的不良反应密切相关,并生成了详细的药物-不良反应报告,及时提醒医生调整患者的治疗方案。

[0198] 系统通过自动化分析,生成了如下报告:

[0199] 实体:高血压、氨氯地平、头痛、恶心;

[0200] 关系:药物-治疗疾病、药物-引发不良反应;

[0201] 验证时间:2秒(基于知识库快速验证);

[0202] 为了更直观地展示效果,医院对1000份含有复杂症状描述的病例数据进行了对比测试。在测试中,传统的基于规则的NLP模型无法准确识别超过50%的并发症,而本发明的方法能够精准提取超过85%的并发症,实施例1中,在一份描述为“患者因慢性胃炎服用泮托拉唑,近期出现胃痛和反酸症状”的病例中,传统方法无法有效提取“胃痛”和“反酸”与药物的关联性,而本发明的方法则准确识别并生成了药物-症状的关联报告。

[0203] 在2023年9月的一次急诊病例处理中,本发明的方法再次展示了其在复杂医学场景中的高效性,急诊科收到了一名急性心梗患者的病例,描述为“患者突发胸痛、呼吸急促,医生注射阿托品后症状缓解,但随后出现视物模糊。”传统方法只能识别出“胸痛”和“呼吸急促”作为心梗的直接症状,而本发明的方法通过上下文和知识库验证,不仅识别出“视物模糊”作为阿托品的潜在不良反应,还自动生成了药物与症状关联的风险报告,帮助医生迅速调整治疗方案,避免了更严重的不良反应发生。

[0204] 在这次急诊处理中,本发明的方法的实际运行数据如下:

[0205] 实体识别时间:10秒,实体关系提取准确率:94.6%,不良反应检测率:92.4%,系

统生成完整报告时间:3分钟。

[0206] 通过一系列的真实场景测试,本发明的方法在医疗实体识别与关系抽取上展现出了其卓越的性能,与传统的NLP模型相比,本发明的方法在复杂医疗场景中的实体识别准确率、关系抽取效率及处理时间上均显著优于传统方法,在紧急医疗场景下,本发明的方法能够及时发现潜在的不良反应,准确关联药物与症状,并生成详细的分析报告,帮助医生快速做出诊断决策,从而有效提升了医疗服务质量。

[0207] 本发明通过引入基于医疗领域优化的词嵌入模型,结合医疗术语的专业词典与语料库训练模型,显著提升了实体识别的准确性,利用Attention机制捕捉医疗术语及其语境信息,词嵌入模型有效处理医学文本中的多义词和缩写问题,解决了传统NLP模型在面对专业医学术语时容易发生的误分类与漏识别问题,同时,结合双向长短期记忆网络,模型能够捕获文本中的上下文信息,从而进一步增强了实体识别的语义理解能力,使识别结果更加精确。

[0208] 本发明提出了基于双向Attention机制和上下文感知的关系抽取方法,能够自动识别并推断出医疗文本中复杂的实体关系,通过全局与局部的Attention机制相结合,不仅能识别实体之间的直接关系,还能通过上下文信息推断出隐含的潜在关系,结合医疗领域知识库中的关系向量,模型在抽取复杂语义关联时能够自动进行验证与补充,有效解决了现有技术在处理多层次语义关系时信息丢失的难题,大幅提升了模型在复杂场景下的关系抽取能力。

[0209] 本发明通过引入医疗领域知识库对识别出的实体和关系进行自动验证与补充,解决了现有技术中无法充分利用医疗领域知识的问题,通过匹配评分和相似度计算,系统能够动态调整低匹配实体和关系的识别结果,结合领域知识进行有效的补充验证,保证了实体和关系的准确性,通过知识库的交叉验证机制,模型可以自动修正识别中的误差,减少了由于数据缺失或语义模糊带来的错误识别,进一步提升医疗文本分析的可靠性和实用性。

[0210] 以上所述,仅为本发明较佳的具体实施方式,但本发明的保护范围并不局限于此,任何熟悉本技术领域的技术人员在本发明揭露的技术范围内,根据本发明的技术方案及其发明构思加以等同替换或改变,都应涵盖在本发明的保护范围之内。




图1




图2