



(12) 发明专利

(10) 授权公告号 CN 119227794 B

(45) 授权公告日 2025.06.13

(21) 申请号 202411366962.9

G06F 40/30 (2020.01)

(22) 申请日 2024.09.29

G06N 3/0895 (2023.01)

(65) 同一申请的已公布的文献号

申请公布号 CN 119227794 A

(56) 对比文件

CN 117952209 A, 2024.04.30

CN 116521818 A, 2023.08.01

(43) 申请公布日 2024.12.31

审查员 郝羽娜

(73) 专利权人 广西警察学院

地址 530028 广西壮族自治区南宁市青秀区
区长湖路6号(72) 发明人 秦振凯 饶宜可 吴田阳 周亮明
林明友 古先铭(74) 专利代理机构 江苏昌禾律师事务所 32837
专利代理师 潘天志

(51) Int. Cl.

G06N 5/022 (2023.01)

G06N 5/04 (2023.01)


权利要求书4页 说明书11页 附图1页

(54) 发明名称

基于大语言模型的多模态文档结构化处理
与知识提取方法

(57) 摘要

本发明公开了一种基于大语言模型的多模态文档结构化处理与知识提取方法, S1、接收输入的多模态文档; S2、对所述多模态文档中的文本数据进行预处理; S3、对所述多模态文档中的非文本数据进行特征提取; S4、将预处理后的文本数据与特征提取后的非文本数据进行多模态数据融合; S5、通过预先训练的改进BERT模型对所述融合后的多模态数据进行深度语义分析, 包括关键实体识别、关系抽取及事件检测; S6、基于所述深度语义分析的结果, 自动化地将提取的信息构建知识图谱; S7、将知识图谱的数据输出为可供分析或应用的格式。本发明实现了对非结构化和多模态文档的结构化处理和知识提取。



1.一种基于大语言模型的多模态文档结构化处理与知识提取方法,其特征在于,包括如下步骤:

S1、接收输入的多模态文档,所述多模态文档包含至少一种文本数据和至少一种非文本数据;

S2、对所述多模态文档中的文本数据进行预处理,所述预处理包括分词、词性标注、句法分析及实体识别;

S3、对所述多模态文档中的非文本数据进行特征提取;

S4、将预处理后的文本数据与特征提取后的非文本数据进行多模态数据融合;

S5、通过预先训练的改进BERT模型对所述融合后的多模态数据进行深度语义分析;

S6、基于所述深度语义分析的结果,自动化地将提取的信息构建知识图谱;

S7、将知识图谱的数据输出为可供分析或应用的格式;

所述步骤S5包括:

S51、将融合后的多模态特征矩阵 M_t 输入至预先训练的改进BERT模型执行深度语义分析,改进BERT模型对文本和非文本数据的嵌入表示进行联合编码,生成多模态语义向量 S_v ;

S52、通过注意力机制在多模态语义向量 M_t 中执行关键实体识别,改进BERT模型计算每个词和非文本特征的注意力权重,识别出多模态数据中的关键实体 E_k :

$$E_k = \arg \max_E \sum_{i=1}^n \alpha_i \cdot \text{Att}(S_{vi}, T_{di});$$

其中, S_{vi} 表示多模态语义向量中的第*i*个词或特征, T_{di} 表示相应的文本词语, α_i 表示注意力权重;

S53、基于改进BERT模型的深度语义关系抽取模块,计算多模态语义向量中的实体之间的关系 $R_s(E_k)$,并通过事件检测模块在多模态语义向量中识别出事件 Ev_s ;

所述步骤S6包括:

S61、基于深度语义分析的结果从多模态语义向量 S_v 提取文本实体节点 E_t 和非文本实体节点 E_n ,构建知识图谱的初始节点集 N_g :

文本实体节点 E_t 表示从文本数据中提取的人物、地名和事件;

非文本实体节点 E_n 表示从图像和图表非文本数据中提取的物体和数据点;

S62、根据文本数据与非文本数据之间的语义关系生成节点之间的边 L_g ,所述边包括表示文本描述与图像中对象之间关系的边和表示图表数据与文本描述之间关系的边;

S63、基于图结构学习模型对节点和边的权重 ω_n 和 ω_l 进行优化生成优化后的知识图谱 K_g 。

2.根据权利要求1所述的一种基于大语言模型的多模态文档结构化处理与知识提取方法,其特征在于,所述步骤S1包括:

S11、接收由多个数据源提供的多模态文档输入信号,所述数据源包括文本数据源和非文本数据源,所述文本数据源提供包含自然语言内容的文本数据,所述非文本数据源提供图像、图表或其他类型的非文本数据:

$$D_m = (\sum_{i=1}^{N_t} T_{di}) \oplus (\sum_{j=1}^{N_n} N_{dj});$$

其中, D_m 表示接收到的多模态文档输入数据集, T_{di} 表示第*i*个文本数据单元, N_{dj} 表示第*j*

个非文本数据单元, N_t 和 N_n 分别表示文本数据和非文本数据的数量, $\oplus$ 表示多模态数据的并行接收和组合操作;

S12、对文本数据 T_d 和非文本数据 N_d 进行同步输入操作, 使文本数据和非文本数据同时导入到处理系统中;

S13、对输入的文本数据 T_d 和非文本数据 N_d 进行初步数据类型识别, 基于元数据标识 M_t 对文本数据类型进行验证, 通过图像特征矩阵 I_f 验证非文本数据类型;

S14、根据识别结果, 将文本数据 T_d 和非文本数据 N_d 分类存储于文本数据缓存单元 C_t 和非文本数据缓存单元 C_n 中。

3. 根据权利要求1所述的一种基于大语言模型的多模态文档结构化处理与知识提取方法, 其特征在于, 所述步骤S2包括:

S21、使用基于上下文注意力机制的词汇匹配算法对接收的文本数据 T_d 进行分词处理, 执行分词操作:

$$L_m(T_d) = \sum_{i=1}^n (\alpha_i \cdot W(T_{di}) + \beta_i \cdot \frac{1}{|C(T_{di})|} \sum_{T_j \in C(T_{di})} \text{Sim}(T_{di}, T_j));$$

其中, T_d 表示输入的文本数据, T_{di} 表示文本数据中的第 i 个词, $L_m(T_d)$ 是分词处理结果, α_i 和 β_i 分别表示全局词典匹配权重和上下文相似度权重, $W(T_{di})$ 表示词典中的词条匹配得分, $C(T_{di})$ 表示词 T_{di} 的上下文词集, $\text{Sim}(T_{di}, T_j)$ 表示词 T_{di} 与上下文词 T_j 的相似度;

S22、使用基于条件随机场的词性标注模型对分词后的文本数据进行词性标注, 词性标注过程如下:

$$P_s(T_d) = \arg \max_P \prod_{i=1}^n \psi(T_{di}, P_{di}) \cdot \phi(P_{di-1}, P_{di});$$

其中, T_{di} 表示第 i 个词, P_{di} 表示对应的词性标签, $\psi(T_{di}, P_{di})$ 表示词 T_{di} 与其词性 P_{di} 之间的兼容性函数, $\phi(P_{di-1}, P_{di})$ 表示词性转移概率, $P_s(T_d)$ 表示分词后文本数据的词性标注集合;

S23、对标注后的文本数据进行句法分析, 使用依存树句法分析模型构建文本的语法结构树, 具体过程如下:

$$S_t(T_d) = \sum_{i=1}^n \sum_{j=1}^n \delta(T_{di}, T_{dj}) \cdot \tau(P_{di}, P_{dj}) \cdot \text{Dep}(T_{di}, T_{dj});$$

其中, T_{di} 和 T_{dj} 表示文本中的两个词, $\delta(T_{di}, T_{dj})$ 表示词语间的距离, $\tau(P_{di}, P_{dj})$ 表示词性之间的依存关系权重, $\text{Dep}(T_{di}, T_{dj})$ 表示词语间的依存关系强度, $S_t(T_d)$ 表示文本数据的句法结构树;

S24、使用基于双向长短期记忆和条件随机场的实体识别模型对经过句法分析的文本数据进行实体识别, 执行实体识别:

$$E_r(T_d) = \arg \max_E \prod_{i=1}^n \lambda(T_{di}, E_{di}) + \mu(E_{di-1}, E_{di}) + \gamma \cdot \sum_{j=1}^m \text{Att}(T_{di}, F_j);$$

其中, T_{di} 表示文本中的第 i 个词, E_{di} 表示对应的实体标签, $\lambda(T_{di}, E_{di})$ 表示词与实体标签之间的兼容性得分, $\mu(E_{di-1}, E_{di})$ 表示实体标签间的转移得分, γ 表示多模态数据之间的融合系数, $\text{Att}(T_{di}, F_j)$ 表示文本词 T_{di} 与非文本数据特征 F_j 的注意力权重, $E_r(T_d)$ 表示文本数据中的实体识别结果。

4. 根据权利要求1所述的一种基于大语言模型的多模态文档结构化处理与知识提取方

法,其特征在于,所述步骤S3包括:

S31、对多模态文档中的图像数据 I_d 进行视觉特征提取,使用卷积神经网络对图像数据中的空间特征进行分析提取图像特征向量 V_i :

$$V_i = \sum_{l=1}^L \sum_{k=1}^K w_{lk} \cdot f(I_{lk}) + b_{lk};$$

其中, I_d 表示输入的图像数据, I_{lk} 表示图像中的第 l 层和第 k 个特征点, w_{lk} 表示权重参数, $f(I_{lk})$ 表示图像特征点的非线性激活函数, b_{lk} 表示偏置值, V_i 表示图像的视觉特征向量;

S32、使用基于区域提案网络的模型对图像数据中的目标对象进行检测,生成候选区域框 R_i ,并对每个区域框执行目标分类:

$$R_i = \arg \max_R (\sum_{p=1}^P \phi(R_{pi}) \cdot \text{IoU}(R_{pi}, O_i));$$

其中, R_{pi} 表示第 i 个候选区域, O_i 表示真实目标区域, P 表示候选区域的数量, $\phi(R_{pi})$ 为区域提案的置信度评分, $\text{IoU}(R_{pi}, O_i)$ 表示候选区域与真实目标区域之间的交并比;

S33、对多模态文档中的图表数据 G_d 进行结构识别,提取图表中的关键结构信息 S_g ,包括坐标轴、数据点、标签和线条关系:

$$S_g = \sum_{j=1}^J \gamma_j \cdot \text{Rel}(G_{dj}, L_j);$$

其中, G_d 表示输入的图表数据, G_{dj} 表示图表中的第 j 个数据元素, L_j 表示与数据元素相关的标签, γ_j 表示权重参数, $\text{Rel}(G_{dj}, L_j)$ 表示图表数据元素与其标签之间的关联关系强度, S_g 表示图表的结构识别结果。

5. 根据权利要求1所述的一种基于大语言模型的多模态文档结构化处理与知识提取方法,其特征在于,所述步骤S4包括:

S41、将预处理后的文本数据 T_d 的特征向量 $P_s(T_d)$ 与特征提取后的非文本数据 N_v 进行特征向量融合,构建多模态特征矩阵 M_f :

$$M_f = \lambda_1 \cdot P_s(T_d) + \lambda_2 \cdot (V_i \oplus S_g);$$

其中, $P_s(T_d)$ 表示文本数据的词性标注特征向量, V_i 表示图像数据的视觉特征向量, S_g 表示图表数据的结构特征, λ_1 和 λ_2 分别表示文本和非文本数据的融合权重, M_f 表示融合后的多模态特征矩阵;

S42、基于注意力机制计算文本数据与非文本数据之间的关联性得分 $A_s(T_d, N_d)$,其中,文本数据的分词结果 $L_m(T_d)$ 与非文本数据的候选区域框 R_i 用于计算相似性得分:

$$A_s(T_d, N_d) = \sum_{i=1}^n \sum_{j=1}^m \alpha_{ij} \cdot \text{Sim}(L_m(T_{di}), R_j);$$

其中, $L_m(T_{di})$ 表示文本数据中的分词结果, R_j 表示非文本数据中的候选区域, α_{ij} 表示文本数据与非文本数据之间的注意力权重, $\text{Sim}(L_m(T_{di}), R_j)$ 表示文本数据词与非文本数据候选区域之间的相似度得分, $A_s(T_d, N_d)$ 表示文本数据与非文本数据的关联性得分;

S43、基于关联性得分 $A_s(T_d, N_d)$ 对多模态数据进行信息融合生成最终的多模态特征矩阵 M_r :

$$M_r = \sum_{i=1}^n \sum_{j=1}^m \beta_{ij} \cdot (L_m(T_{di}) \oplus (V_i \oplus S_g));$$

其中, β_{ij} 表示融合后的权重系数, $L_m(T_{di}) \oplus (V_i \oplus S_g)$ 表示文本数据词与图像及图表特征的融合操作, M_r 表示最终生成的多模态表示。

6. 根据权利要求1所述的一种基于大语言模型的多模态文档结构化处理与知识提取方法, 其特征在于, 所述步骤S63包括:

S631、基于图结构学习模型对初始知识图谱中的节点权重 ω_n 和边权重 ω_l 进行初始化, 节点权重 ω_n 初始化为节点的度数, 边权重 ω_l 初始化为节点间的关联强度;

S632、基于梯度下降算法优化节点权重和边权重, 迭代更新节点和边的权重值 ω_n^{t+1} 和 ω_l^{t+1} :

$$\omega_n^{t+1} = \omega_n^t - \eta_2 \cdot \frac{\partial L}{\partial \omega_n^t};$$

$$\omega_l^{t+1} = \omega_l^t - \eta_2 \cdot \frac{\partial L}{\partial \omega_l^t};$$

其中, η_2 为学习率, $\frac{\partial L}{\partial \omega_n^t}$ 和 $\frac{\partial L}{\partial \omega_l^t}$ 分别表示损失函数L对节点权重和边权重的偏导数;

S633、损失函数L通过最小化节点和边之间的误差来进行优化, 优化的目的是通过最小化L提升知识图谱的准确性和关联性:

$$L = \sum_{i=1}^n \sum_{j=1}^m (\omega_{l_{ij}} \cdot \text{Sim}(E_i, E_j) - \omega_{n_i} \cdot \omega_{n_j})^2;$$

其中, $\text{Sim}(E_i, E_j)$ 表示节点 E_i 与节点 E_j 之间的相似性, L 表示节点和边之间的总损失;

S634、在优化迭代过程中, 根据最优的节点权重 ω_n^* 和边权重 ω_l^* 生成最终优化后的知识图谱 K_g :

$$K_g = \{N_g, L_g, \omega_n^*, \omega_l^*\};$$

其中, K_g 表示最终优化后的知识图谱, 包含优化后的节点集 N_g 、边集 L_g 以及节点权重 ω_n^* 和边权重 ω_l^* 。

基于大语言模型的多模态文档结构化处理与知识提取方法

技术领域

[0001] 本发明涉及多模态文档技术领域,尤其涉及一种基于大语言模型的多模态文档结构化处理与知识提取方法。

背景技术

[0002] 现有技术中针对非结构化、多模态文档的处理主要依赖于单一模态的数据处理方式,如仅处理文本、图像或图表中的某一种类型数据,现有技术的处理方法虽然在某些场景下可以有效实现信息的提取和处理,但当面对包含多种模态数据的复杂文档时,现有技术显得力不从心,传统的单模态处理方式无法有效地将多种类型的数据进行融合分析,导致在信息提取和知识表示方面存在明显的局限性,尤其是在需要自动化处理大量非结构化、多模态文档时,传统技术往往需要依赖大量的人工干预,无法实现高效的自动化处理。

[0003] 现有技术中,文本处理技术如自然语言处理已发展较为成熟,尤其是基于BERT大语言模型的应用可以实现一定的文本语义理解、分词、词性标注功能,但这些大多只针对纯文本数据,缺乏对非文本数据的处理能力,而针对图像和图表的特征提取技术,多采用卷积神经网络视觉模型,但模型无法与文本数据进行深度融合,导致从多模态数据中提取知识的精度和广泛性不足。

[0004] 综上所述,现有技术主要存在以下缺点:首先,现有的单模态处理方式在多模态文档处理中的适用性较差,缺乏有效的多模态数据融合方法;其次,现有的文本处理和视觉特征提取技术彼此割裂,无法实现对多模态数据的联合理解。

发明内容

[0005] 本发明的一个目的在于提出一种基于大语言模型的多模态文档结构化处理与知识提取方法,本发明实现了对非结构化和多模态文档的结构化处理和知识提取。

[0006] 根据本发明实施例的一种基于大语言模型的多模态文档结构化处理与知识提取方法,包括如下步骤:

[0007] S1、接收输入的多模态文档,所述多模态文档包含至少一种文本数据和至少一种非文本数据;

[0008] S2、对所述多模态文档中的文本数据进行预处理,所述预处理包括分词、词性标注、句法分析及实体识别;

[0009] S3、对所述多模态文档中的非文本数据进行特征提取;

[0010] S4、将预处理后的文本数据与特征提取后的非文本数据进行多模态数据融合;

[0011] S5、通过预先训练的改进BERT模型对所述融合后的多模态数据进行深度语义分析;

[0012] S6、基于所述深度语义分析的结果,自动化地将提取的信息构建知识图谱;

[0013] S7、将知识图谱的数据输出为可供分析或应用的格式。

[0014] 可选的,所述步骤S1包括:

[0015] S11、接收由多个数据源提供的多模态文档输入信号,所述数据源包括文本数据源和非文本数据源,所述文本数据源提供包含自然语言内容的文本数据,所述非文本数据源提供图像、图表或其他类型的非文本数据:

$$[0016] \quad D_m = (\sum_{i=1}^{N_t} T_{di}) \oplus (\sum_{j=1}^{N_n} N_{dj});$$

[0017] 其中, D_m 表示接收到的多模态文档输入数据集, T_{di} 表示第*i*个文本数据单元, N_{dj} 表示第*j*个非文本数据单元, N_t 和 N_n 分别表示文本数据和非文本数据的数量, $\oplus$ 表示多模态数据的并行接收和组合操作;

[0018] S12、对文本数据 T_d 和非文本数据 N_d 进行同步输入操作,使文本数据和非文本数据同时导入到处理系统中;

[0019] S13、对输入的文本数据 T_d 和非文本数据 N_d 进行初步数据类型识别,基于元数据标识 M_t 对文本数据类型进行验证,通过图像特征矩阵 I_f 验证非文本数据类型;

[0020] S14、根据识别结果,将文本数据 T_d 和非文本数据 N_d 分类存储于文本数据缓存单元 C_t 和非文本数据缓存单元 C_n 中。

[0021] 可选的,所述步骤S2包括:

[0022] S21、使用基于上下文注意力机制的词汇匹配算法对接收的文本数据 T_d 进行分词处理,执行分词操作:

$$[0023] \quad L_m(T_d) = \sum_{i=1}^n (\alpha_i \cdot W(T_{di}) + \beta_i \cdot \frac{1}{|C(T_{di})|} \sum_{T_j \in C(T_{di})} \text{Sim}(T_{di}, T_j));$$

[0024] 其中, T_d 表示输入的文本数据, T_{di} 表示文本数据中的第*i*个词, $L_m(T_d)$ 是分词处理结果, α_i 和 β_i 分别表示全局词典匹配权重和上下文相似度权重, $W(T_{di})$ 表示词典中的词条匹配得分, $C(T_{di})$ 表示词 T_{di} 的上下文词集, $\text{Sim}(T_{di}, T_j)$ 表示词 T_{di} 与上下文词 T_j 的相似度;

[0025] S22、使用基于条件随机场的词性标注模型对分词后的文本数据进行词性标注,词性标注过程如下:

$$[0026] \quad P_s(T_d) = \arg \max_P \prod_{i=1}^n \psi(T_{di}, P_{di}) \cdot \phi(P_{di-1}, P_{di});$$

[0027] 其中, T_{di} 表示第*i*个词, P_{di} 表示对应的词性标签, $\psi(T_{di}, P_{di})$ 表示词 T_{di} 与其词性 P_{di} 之间的兼容性函数, $\phi(P_{di-1}, P_{di})$ 表示词性转移概率, $P_s(T_d)$ 表示分词后文本数据的词性标注集合;

[0028] S23、对标注后的文本数据进行句法分析,使用依存树句法分析模型构建文本的语法结构树,具体过程如下:

$$[0029] \quad S_t(T_d) = \sum_{i=1}^n \sum_{j=1}^n \delta(T_{di}, T_{dj}) \cdot \tau(P_{di}, P_{dj}) \cdot \text{Dep}(T_{di}, T_{dj});$$

[0030] 其中, T_{di} 和 T_{dj} 表示文本中的两个词, $\delta(T_{di}, T_{dj})$ 表示词语间的距离, $\tau(P_{di}, P_{dj})$ 表示词性之间的依存关系权重, $\text{Dep}(T_{di}, T_{dj})$ 表示词语间的依存关系强度, $S_t(T_d)$ 表示文本数据的句法结构树;

[0031] S24、使用基于双向长短期记忆和条件随机场的实体识别模型对经过句法分析的文本数据进行实体识别,执行实体识别:

$$[0032] \quad E_r(T_d) = \arg \max_E \prod_{i=1}^n \lambda(T_{di}, E_{di}) + \mu(E_{di-1}, E_{di}) + \gamma \cdot \sum_{j=1}^m \text{Att}(T_{di}, F_j);$$

[0033] 其中, T_{di} 表示文本中的第 i 个词, E_{di} 表示对应的实体标签, $\lambda(T_{di}, E_{di})$ 表示词与实体标签之间的兼容性得分, $\mu(E_{di-1}, E_{di})$ 表示实体标签间的转移得分, γ 表示多模态数据之间的融合系数, $Att(T_{di}, F_j)$ 表示文本词 T_{di} 与非文本数据特征 F_j 的注意力权重, $E_r(T_d)$ 表示文本数据中的实体识别结果。

[0034] 可选的, 所述步骤 S3 包括:

[0035] S31、对多模态文档中的图像数据 I_d 进行视觉特征提取, 使用卷积神经网络对图像数据中的空间特征进行分析提取图像特征向量 V_i :

$$[0036] \quad V_i = \sum_{l=1}^L \sum_{k=1}^K w_{lk} \cdot f(I_{lk}) + b_{lk};$$

[0037] 其中, I_d 表示输入的图像数据, I_{lk} 表示图像中的第 l 层和第 k 个特征点, w_{lk} 表示权重参数, $f(I_{lk})$ 表示图像特征点的非线性激活函数, b_{lk} 表示偏置值, V_i 表示图像的视觉特征向量;

[0038] S32、使用基于区域提案网络的模型对图像数据中的目标对象进行检测, 生成候选区域框 R_i , 并对每个区域框执行目标分类:

$$[0039] \quad R_i = \arg \max_R (\sum_{p=1}^P \phi(R_{pi}) \cdot IoU(R_{pi}, O_i));$$

[0040] 其中, R_{pi} 表示第 i 个候选区域, O_i 表示真实目标区域, P 表示候选区域的数量, $\phi(R_{pi})$ 为区域提案的置信度评分, $IoU(R_{pi}, O_i)$ 表示候选区域与真实目标区域之间的交并比;

[0041] S33、对多模态文档中的图表数据 G_d 进行结构识别, 提取图表中的关键结构信息 S_g , 包括坐标轴、数据点、标签和线条关系:

$$[0042] \quad S_g = \sum_{j=1}^J \gamma_j \cdot Rel(G_{dj}, L_j);$$

[0043] 其中, G_d 表示输入的图表数据, G_{dj} 表示图表中的第 j 个数据元素, L_j 表示与数据元素相关的标签, γ_j 表示权重参数, $Rel(G_{dj}, L_j)$ 表示图表数据元素与其标签之间的关联关系强度, S_g 表示图表的结构识别结果。

[0044] 可选的, 所述步骤 S4 包括:

[0045] S41、将预处理后的文本数据 T_d 的特征向量 $P_s(T_d)$ 与特征提取后的非文本数据 N_v 进行特征向量融合, 构建多模态特征矩阵 M_f :

$$[0046] \quad M_f = \lambda_1 \cdot P_s(T_d) + \lambda_2 \cdot (V_i \oplus S_g);$$

[0047] 其中, $P_s(T_d)$ 表示文本数据的词性标注特征向量, V_i 表示图像数据的视觉特征向量, S_g 表示图表数据的结构特征, λ_1 和 λ_2 分别表示文本和非文本数据的融合权重, M_f 表示融合后的多模态特征矩阵;

[0048] S42、基于注意力机制计算文本数据与非文本数据之间的关联性得分 $A_s(T_d, N_d)$, 其中, 文本数据的分词结果 $L_m(T_d)$ 与非文本数据的候选区域框 R_i 用于计算相似性得分:

$$[0049] \quad A_s(T_d, N_d) = \sum_{i=1}^n \sum_{j=1}^m \alpha_{ij} \cdot Sim(L_m(T_{di}), R_j);$$

[0050] 其中, $L_m(T_{di})$ 表示文本数据中的分词结果, R_j 表示非文本数据中的候选区域, α_{ij} 表示文本数据与非文本数据之间的注意力权重, $Sim(L_m(T_{di}), R_j)$ 表示文本数据词与非文本数

据候选区域之间的相似度得分, $A_s(T_d, N_d)$ 表示文本数据与非文本数据的关联性得分;

[0051] S43、基于关联性得分 $A_s(T_d, N_d)$ 对多模态数据进行信息融合生成最终的多模态特征矩阵 M_r :

$$[0052] \quad M_r = \sum_{i=1}^n \sum_{j=1}^m \beta_{ij} \cdot (L_m(T_{di}) \oplus (V_i \oplus S_g));$$

[0053] 其中, β_{ij} 表示融合后的权重系数, $L_m(T_{di}) \oplus (V_i \oplus S_g)$ 表示文本数据词与图像及图表特征的融合操作, M_r 表示最终生成的多模态表示。

[0054] 可选的, 所述步骤S5包括:

[0055] S51、将融合后的多模态特征矩阵 M_r 输入至预先训练的改进BERT模型执行深度语义分析, 改进BERT模型对文本和非文本数据的嵌入表示进行联合编码, 生成多模态语义向量 S_v ;

[0056] S52、通过注意力机制在多模态语义向量 M_r 中执行关键实体识别, 改进BERT模型计算每个词和非文本特征的注意力权重, 识别出多模态数据中的关键实体 E_k :

$$[0057] \quad E_k = \arg \max_E \sum_{i=1}^n \alpha_i \cdot \text{Att}(S_{vi}, T_{di});$$

[0058] 其中, S_{vi} 表示多模态语义向量中的第 i 个词或特征, T_{di} 表示相应的文本词语, α_i 表示注意力权重;

[0059] S53、基于改进BERT模型的深度语义关系抽取模块, 计算多模态语义向量中的实体之间的关系 $R_s(E_k)$, 并通过事件检测模块在多模态语义向量中识别出事件 Ev_s 。

[0060] 可选的, 所述步骤S6包括:

[0061] S61、基于深度语义分析的结果从多模态语义向量 S_v 提取文本实体节点 E_t 和非文本实体节点 E_n , 构建知识图谱的初始节点集 N_g :

[0062] 文本实体节点 E_t 表示从文本数据中提取的人物、地名和事件;

[0063] 非文本实体节点 E_n 表示从图像和图表非文本数据中提取的物体和数据点;

[0064] S62、根据文本数据与非文本数据之间的语义关系生成节点之间的边 L_g , 所述边包括表示文本描述与图像中对象之间关系的边和表示图表数据与文本描述之间关系的边;

[0065] S63、基于图结构学习模型对节点和边的权重 ω_n 和 ω_l 进行优化生成优化后的知识图谱 K_g 。

[0066] 可选的, 所述步骤S63包括:

[0067] S631、基于图结构学习模型对初始知识图谱中的节点权重 ω_n 和边权重 ω_l 进行初始化, 节点权重 ω_n 初始化为节点的度数, 边权重 ω_l 初始化为节点间的关联强度;

[0068] S632、基于梯度下降算法优化节点权重和边权重, 迭代更新节点和边的权重值 ω_n^{t+1} 和 ω_l^{t+1} :

$$[0069] \quad \omega_n^{t+1} = \omega_n^t - \eta_2 \cdot \frac{\partial L}{\partial \omega_n^t};$$

$$[0070] \quad \omega_l^{t+1} = \omega_l^t - \eta_2 \cdot \frac{\partial L}{\partial \omega_l^t};$$

[0071] 其中, η_2 为学习率, $\frac{\partial L}{\partial \omega_n^t}$ 和 $\frac{\partial L}{\partial \omega_l^t}$ 分别表示损失函数 L 对节点权重和边权重的偏导数;

[0072] S633、损失函数L通过最小化节点和边之间的误差来进行优化,优化的目的是通过最小化L提升知识图谱的准确性和关联性:

$$[0073] \quad L = \sum_{i=1}^n \sum_{j=1}^m (\omega_{l_{ij}} \cdot \text{Sim}(E_i, E_j) - \omega_{n_i} \cdot \omega_{n_j})^2;$$

[0074] 其中, $\text{Sim}(E_i, E_j)$ 表示节点 E_i 与节点 E_j 之间的相似性, L 表示节点和边之间的总损失;

[0075] S634、在优化迭代过程中,根据最优的节点权重 ω_n^* 和边权重 ω_l^* 生成最终优化后的知识图谱 K_g :

$$[0076] \quad K_g = \{N_g, L_g, \omega_n^*, \omega_l^*\};$$

[0077] 其中, K_g 表示最终优化后的知识图谱,包含优化后的节点集 N_g 、边集 L_g 以及节点权重 ω_n^* 和边权重 ω_l^* 。

[0078] 本发明的有益效果是:

[0079] (1) 本发明通过将文本数据与非文本数据进行融合处理,提出了基于改进BERT模型的多模态融合方法,利用特征提取模型对文本和非文本数据分别进行特征提取,再将其通过自适应的权重机制进行特征融合,生成多模态特征矩阵,不仅提升了文本与图像、图表数据之间的关联性识别精度,还增强了系统对复杂文档的理解能力,使得系统能够从多模态数据中提取更准确、更全面的语义信息,克服了现有技术中单模态处理的局限性。

[0080] (2) 在本发明的技术方案中,基于图结构学习模型对知识图谱的节点权重和边权重进行自适应优化,通过引入梯度下降算法和优化损失函数的计算能够动态调整知识图谱中节点和边的权重分布,优化后的知识图谱能够更精准地表达文本与非文本数据之间的语义关系,相比现有的知识图谱构建技术,本发明不仅能够处理纯文本数据,还可以有效结合图像和图表数据,使构建的知识图谱具有更高的表达能力和精度,确保复杂文档中的关键知识得以全面表示。

[0081] (3) 本发明通过引入改进的BERT模型和自监督学习机制,结合多模态融合技术,显著提高了复杂文档的自动化处理效率,与传统需要大量人工干预的技术不同,本发明能够在无监督或弱监督的情况下通过深度语义分析与实体识别和关系抽取步骤,实现自动化的知识提取和结构化处理,减少了人工操作的复杂度,同时大幅降低了处理多模态文档的时间成本,提高了系统的整体处理效率,解决了现有技术在大规模、多模态文档处理中的效率低下问题。

附图说明

[0082] 附图用来提供对本发明的进一步理解,并且构成说明书的一部分,与本发明的实施例一起用于解释本发明,并不构成对本发明的限制。在附图中:

[0083] 图1为本发明提出的一种基于大语言模型的多模态文档结构化处理与知识提取方法的流程图。

具体实施方式

[0084] 现在结合附图对本发明作进一步详细的说明。这些附图均为简化的示意图,仅以

示意方式说明本发明的基本结构,因此其仅显示与本发明有关的构成。

[0085] 参考图1,一种基于大语言模型的多模态文档结构化处理与知识提取方法,包括如下步骤:

[0086] S1、接收输入的多模态文档,多模态文档包含至少一种文本数据和至少一种非文本数据;

[0087] S2、对多模态文档中的文本数据进行预处理,预处理包括分词、词性标注、句法分析及实体识别;

[0088] S3、对多模态文档中的非文本数据进行特征提取;

[0089] S4、将预处理后的文本数据与特征提取后的非文本数据进行多模态数据融合;

[0090] S5、通过预先训练的改进BERT模型对融合后的多模态数据进行深度语义分析;

[0091] S6、基于深度语义分析的结果,自动化地将提取的信息构建知识图谱;

[0092] S7、将知识图谱的数据输出为可供分析或应用的格式。

[0093] 本实施方式中,步骤S1包括:

[0094] S11、接收由多个数据源提供的多模态文档输入信号,数据源包括文本数据源和非文本数据源,文本数据源提供包含自然语言内容的文本数据,非文本数据源提供图像、图表或其他类型的非文本数据:

$$[0095] \quad D_m = (\sum_{i=1}^{N_t} T_{di}) \oplus (\sum_{j=1}^{N_n} N_{dj});$$

[0096] 其中, D_m 表示接收到的多模态文档输入数据集, T_{di} 表示第*i*个文本数据单元, N_{dj} 表示第*j*个非文本数据单元, N_t 和 N_n 分别表示文本数据和非文本数据的数量, $\oplus$ 表示多模态数据的并行接收和组合操作;

[0097] S12、对文本数据 T_d 和非文本数据 N_d 进行同步输入操作,使文本数据和非文本数据同时导入到处理系统中;

[0098] S13、对输入的文本数据 T_d 和非文本数据 N_d 进行初步数据类型识别,基于元数据标识 M_t 对文本数据类型进行验证,通过图像特征矩阵 I_f 验证非文本数据类型;

[0099] S14、根据识别结果,将文本数据 T_d 和非文本数据 N_d 分类存储于文本数据缓存单元 C_t 和非文本数据缓存单元 C_n 中。

[0100] 本实施方式中,步骤S2包括:

[0101] S21、使用基于上下文注意力机制的词汇匹配算法对接收的文本数据 T_d 进行分词处理,执行分词操作:

$$[0102] \quad L_m(T_d) = \sum_{i=1}^n (\alpha_i \cdot W(T_{di}) + \beta_i \cdot \frac{1}{|C(T_{di})|} \sum_{T_j \in C(T_{di})} \text{Sim}(T_{di}, T_j));$$

[0103] 其中, T_d 表示输入的文本数据, T_{di} 表示文本数据中的第*i*个词, $L_m(T_d)$ 是分词处理结果, α_i 和 β_i 分别表示全局词典匹配权重和上下文相似度权重, $W(T_{di})$ 表示词典中的词条匹配得分, $C(T_{di})$ 表示词 T_{di} 的上下文词集, $\text{Sim}(T_{di}, T_j)$ 表示词 T_{di} 与上下文词 T_j 的相似度;

[0104] S22、使用基于条件随机场的词性标注模型对分词后的文本数据进行词性标注,词性标注过程如下:

$$[0105] \quad P_s(T_d) = \arg \max_P \prod_{i=1}^n \psi(T_{di}, P_{di}) \cdot \phi(P_{di-1}, P_{di});$$

[0106] 其中, T_{di} 表示第 i 个词, P_{di} 表示对应的词性标签, $\psi(T_{di}, P_{di})$ 表示词 T_{di} 与其词性 P_{di} 之间的兼容性函数, $\phi(P_{di-1}, P_{di})$ 表示词性转移概率, $P_s(T_d)$ 表示分词后文本数据的词性标注集合;

[0107] S23、对标注后的文本数据进行句法分析,使用依存树句法分析模型构建文本的语法结构树,具体过程如下:

$$[0108] \quad S_t(T_d) = \sum_{i=1}^n \sum_{j=1}^n \delta(T_{di}, T_{dj}) \cdot \tau(P_{di}, P_{dj}) \cdot \text{Dep}(T_{di}, T_{dj});$$

[0109] 其中, T_{di} 和 T_{dj} 表示文本中的两个词, $\delta(T_{di}, T_{dj})$ 表示词语间的距离, $\tau(P_{di}, P_{dj})$ 表示词性之间的依存关系权重, $\text{Dep}(T_{di}, T_{dj})$ 表示词语间的依存关系强度, $S_t(T_d)$ 表示文本数据的句法结构树;

[0110] S24、使用基于双向长短期记忆和条件随机场的实体识别模型对经过句法分析的文本数据进行实体识别,执行实体识别:

$$[0111] \quad E_r(T_d) = \arg \max_E \prod_{i=1}^n \lambda(T_{di}, E_{di}) + \mu(E_{di-1}, E_{di}) + \gamma \cdot \sum_{j=1}^m \text{Att}(T_{di}, F_j);$$

[0112] 其中, T_{di} 表示文本中的第 i 个词, E_{di} 表示对应的实体标签, $\lambda(T_{di}, E_{di})$ 表示词与实体标签之间的兼容性得分, $\mu(E_{di-1}, E_{di})$ 表示实体标签间的转移得分, γ 表示多模态数据之间的融合系数, $\text{Att}(T_{di}, F_j)$ 表示文本词 T_{di} 与非文本数据特征 F_j 的注意力权重, $E_r(T_d)$ 表示文本数据中的实体识别结果。

[0113] 本实施方式中,步骤S3包括:

[0114] S31、对多模态文档中的图像数据 I_d 进行视觉特征提取,使用卷积神经网络对图像数据中的空间特征进行分析提取图像特征向量 V_i :

$$[0115] \quad V_i = \sum_{l=1}^L \sum_{k=1}^K w_{lk} \cdot f(I_{lk}) + b_{lk};$$

[0116] 其中, I_d 表示输入的图像数据, I_{lk} 表示图像中的第 l 层和第 k 个特征点, w_{lk} 表示权重参数, $f(I_{lk})$ 表示图像特征点的非线性激活函数, b_{lk} 表示偏置值, V_i 表示图像的视觉特征向量;

[0117] S32、使用基于区域提案网络的模型对图像数据中的目标对象进行检测,生成候选区域框 R_i ,并对每个区域框执行目标分类:

$$[0118] \quad R_i = \arg \max_R (\sum_{p=1}^P \phi(R_{pi}) \cdot \text{IoU}(R_{pi}, O_i));$$

[0119] 其中, R_{pi} 表示第 i 个候选区域, O_i 表示真实目标区域, P 表示候选区域的数量, $\phi(R_{pi})$ 为区域提案的置信度评分, $\text{IoU}(R_{pi}, O_i)$ 表示候选区域与真实目标区域之间的交并比;

[0120] S33、对多模态文档中的图表数据 G_d 进行结构识别,提取图表中的关键结构信息 S_g ,包括坐标轴、数据点、标签和线条关系:

$$[0121] \quad S_g = \sum_{j=1}^J \gamma_j \cdot \text{Rel}(G_{dj}, L_j);$$

[0122] 其中, G_d 表示输入的图表数据, G_{dj} 表示图表中的第 j 个数据元素, L_j 表示与数据元素相关的标签, γ_j 表示权重参数, $\text{Rel}(G_{dj}, L_j)$ 表示图表数据元素与其标签之间的关联关系强度, S_g 表示图表的结构识别结果。

[0123] 本实施方式中,步骤S4包括:

[0124] S41、将预处理后的文本数据 T_d 的特征向量 $P_s(T_d)$ 与特征提取后的非文本数据 N_v 进行特征向量融合,构建多模态特征矩阵 M_f :

$$[0125] \quad M_f = \lambda_1 \cdot P_s(T_d) + \lambda_2 \cdot (V_i \oplus S_g);$$

[0126] 其中, $P_s(T_d)$ 表示文本数据的词性标注特征向量, V_i 表示图像数据的视觉特征向量, S_g 表示图表数据的结构特征, λ_1 和 λ_2 分别表示文本和非文本数据的融合权重, M_f 表示融合后的多模态特征矩阵;

[0127] S42、基于注意力机制计算文本数据与非文本数据之间的关联性得分 $A_s(T_d, N_d)$,其中,文本数据的分词结果 $L_m(T_d)$ 与非文本数据的候选区域框 R_i 用于计算相似性得分:

$$[0128] \quad A_s(T_d, N_d) = \sum_{i=1}^n \sum_{j=1}^m \alpha_{ij} \cdot \text{Sim}(L_m(T_{di}), R_j);$$

[0129] 其中, $L_m(T_{di})$ 表示文本数据中的分词结果, R_j 表示非文本数据中的候选区域, α_{ij} 表示文本数据与非文本数据之间的注意力权重, $\text{Sim}(L_m(T_{di}), R_j)$ 表示文本数据词与非文本数据候选区域之间的相似度得分, $A_s(T_d, N_d)$ 表示文本数据与非文本数据的关联性得分;

[0130] S43、基于关联性得分 $A_s(T_d, N_d)$ 对多模态数据进行信息融合生成最终的多模态特征矩阵 M_r :

$$[0131] \quad M_r = \sum_{i=1}^n \sum_{j=1}^m \beta_{ij} \cdot (L_m(T_{di}) \oplus (V_i \oplus S_g));$$

[0132] 其中, β_{ij} 表示融合后的权重系数, $L_m(T_{di}) \oplus (V_i \oplus S_g)$ 表示文本数据词与图像及图表特征的融合操作, M_r 表示最终生成的多模态表示。

[0133] 本实施方式中,步骤S5包括:

[0134] S51、将融合后的多模态特征矩阵 M_r 输入至预先训练的改进BERT模型执行深度语义分析,改进BERT模型对文本和非文本数据的嵌入表示进行联合编码,生成多模态语义向量 S_v ;

[0135] S52、通过注意力机制在多模态语义向量 M_r 中执行关键实体识别,改进BERT模型计算每个词和非文本特征的注意力权重,识别出多模态数据中的关键实体 E_k :

$$[0136] \quad E_k = \arg \max_E \sum_{i=1}^n \alpha_i \cdot \text{Att}(S_{vi}, T_{di});$$

[0137] 其中, S_{vi} 表示多模态语义向量中的第 i 个词或特征, T_{di} 表示相应的文本词语, α_i 表示注意力权重;

[0138] S53、基于改进BERT模型的深度语义关系抽取模块,计算多模态语义向量中的实体之间的关系 $R_s(E_k)$,并通过事件检测模块在多模态语义向量中识别出事件 Ev_s 。

[0139] 本实施方式中,步骤S6包括:

[0140] S61、基于深度语义分析的结果从多模态语义向量 S_v 提取文本实体节点 E_t 和非文本实体节点 E_n ,构建知识图谱的初始节点集 N_g :

[0141] 文本实体节点 E_t 表示从文本数据中提取的人物、地名和事件;

[0142] 非文本实体节点 E_n 表示从图像和图表非文本数据中提取的物体和数据点;

[0143] S62、根据文本数据与非文本数据之间的语义关系生成节点之间的边 L_g ,边包括表示文本描述与图像中对象之间关系的边和表示图表数据与文本描述之间关系的边;

[0144] S63、基于图结构学习模型对节点和边的权重 ω_n 和 ω_l 进行优化生成优化后的知识图谱 K_g 。

[0145] 本实施方式中,步骤S63包括:

[0146] S631、基于图结构学习模型对初始知识图谱中的节点权重 ω_n 和边权重 ω_l 进行初始化,节点权重 ω_n 初始化为节点的度数,边权重 ω_l 初始化为节点间的关联强度;

[0147] S632、基于梯度下降算法优化节点权重和边权重,迭代更新节点和边的权重值 ω_n^{t+1} 和 ω_l^{t+1} :

$$[0148] \quad \omega_n^{t+1} = \omega_n^t - \eta_2 \cdot \frac{\partial L}{\partial \omega_n^t};$$

$$[0149] \quad \omega_l^{t+1} = \omega_l^t - \eta_2 \cdot \frac{\partial L}{\partial \omega_l^t};$$

[0150] 其中, η_2 为学习率, $\frac{\partial L}{\partial \omega_n^t}$ 和 $\frac{\partial L}{\partial \omega_l^t}$ 分别表示损失函数 L 对节点权重和边权重的偏导数;

[0151] S633、损失函数 L 通过最小化节点和边之间的误差来进行优化,优化的目的是通过最小化 L 提升知识图谱的准确性和关联性:

$$[0152] \quad L = \sum_{i=1}^n \sum_{j=1}^m (\omega_{lij} \cdot \text{Sim}(E_i, E_j) - \omega_{n_i} \cdot \omega_{n_j})^2;$$

[0153] 其中, $\text{Sim}(E_i, E_j)$ 表示节点 E_i 与节点 E_j 之间的相似性, L 表示节点和边之间的总损失;

[0154] S634、在优化迭代过程中,根据最优的节点权重 ω_n^* 和边权重 ω_l^* 生成最终优化后的知识图谱 K_g :

$$[0155] \quad K_g = \{N_g, L_g, \omega_n^*, \omega_l^*\};$$

[0156] 其中, K_g 表示最终优化后的知识图谱,包含优化后的节点集 N_g 、边集 L_g 以及节点权重 ω_n^* 和边权重 ω_l^* 。

[0157] 实施例1:

[0158] 在某智能制造工厂的日常设备维护中,工厂使用的技术文档包含文本说明、设备照片、参数表格和操作示意图多种模态的数据,维护手册在设备检修和操作培训中扮演着重要的角色,但文档数据庞大且格式复杂,传统的人工处理方法效率低下,且容易遗漏关键信息,影响了设备的高效运维。

[0159] 2023年8月,工厂在进行某台大型精密数控机床的年度维护时,维护团队需要参照该设备的操作手册进行各项参数检查,设备手册包含25页的文本说明,附有15张设备图片、10个操作示意图以及20个设备参数表格,工厂维护人员通过传统方式处理这份文档,耗时约5天,期间发现多个图表与文本信息的关联错误,导致维护效率下降,为解决这一问题,工厂决定应用本发明的方法以提高效率和准确性。

[0160] 2023年9月初,工厂将该设备的维护手册输入到本发明的系统中,系统首先将文档中的多模态数据进行分解,分别对文本、图像和图表数据进行处理,在文本处理阶段,系统对手册中的设备操作说明进行了分词、词性标注和句法分析,识别出了关键设备名称、操作步骤和维护要求,在图像处理阶段,系统通过卷积神经网络对15张设备图像进行了视觉特

征提取,识别出机床的关键部件,并通过与文本描述的关联分析,自动将图像中的部件与文本中的操作步骤进行配对,在图表处理阶段,系统对20个设备参数表格进行了结构化识别,将关键参数(温度、压力和操作速度)提取并与文本中的操作流程进行关联。

[0161] 为验证系统的性能,我们将本发明的方法与传统的人工处理方法进行了对比。以下为具体的对比数据:

[0162] 表1传统方法与本发明方法的对比数据

[0163]	数据类型	传统方法（人工处理）	本发明方法（自动化处理）
	处理时间	40 小时	3 小时
	关联错误率	8%	1%
	图像与文本配对	需要人工手动标注	自动配对, 准确率 99%
	参数表格识别	手动输入	自动提取, 准确率 98.5%
	知识提取的完整性	仅限文本信息	全模态融合, 完整度 99%
[0164]	人工干预	15 小时	0.5 小时

[0165] 由上表1可以看出,传统方法处理设备手册需要约40小时,包括人工逐页分析文本、图像和图表的关联,而本发明系统仅需3小时即可自动化完成处理,提高了处理速度达13倍。通过深度语义分析和多模态数据融合,本发明系统能够准确提取出维护手册中的关键知识。传统方法在图像与文本的关联标注上容易出现错误,错误率为8%,而本系统自动化标注,错误率仅为1%。传统方法中,工厂技术人员需要手动将设备图像与操作步骤进行配对,容易产生误配。本发明的系统通过视觉特征提取与文本关联分析,能够自动完成配对,且准确率达到99%。设备手册中包含的20个参数表格在传统方法中需要人工手动输入,而本发明系统通过结构化识别,能够自动提取参数数据并与文本描述相匹配,识别准确率达到98.5%。传统方法中,知识提取仅限于纯文本信息,无法有效处理图像和图表中的数据。本发明系统能够将文本、图像和图表信息融合,生成完整的知识图谱,确保多模态信息的完整性,完整度达99%。传统方法中,人工干预需要大量时间,特别是在图像与文本的关联标注以及参数表格的输入方面,需占用15小时人工时间。而本发明系统自动化程度较高,整个过程中仅需0.5小时的人工复核,大幅减少了人力投入。

[0166] 在2023年9月的一次实际操作中,维护人员使用本发明的系统对精密数控机床的维护手册进行了处理,系统首先识别并提取出文本中的“设备型号:NC-5000”以及“关键部件:主轴、刀架”关键信息,随后,系统通过图像处理模块识别出维护手册中与这些部件相关的设备照片,并与操作步骤自动匹配,,系统将“主轴维护”与对应的设备图像进行了关联标注,并进一步分析了参数表中的“主轴转速范围”与“操作温度”,最终在知识图谱中形成了设备的全局信息展示。

[0167] 在此过程中,系统还自动生成了一份维护报告,报告内容包括设备的关键部件、操作步骤、相关参数以及图像、图表信息的关联结果,报告随后被提交给维护团队,作为设备维护操作的参考文件。

[0168] 通过这次应用,工厂的维护效率得到了显著提升,维护人员反馈系统提供的信息结构清晰、操作步骤明确,减少了以往人工查阅和关联图像、参数表格的工作量。

[0169] 本发明通过将文本数据与非文本数据进行融合处理,提出了基于改进BERT模型的多模态融合方法,利用特征提取模型对文本和非文本数据分别进行特征提取,再将其通过

自适应的权重机制进行特征融合,生成多模态特征矩阵,不仅提升了文本与图像、图表数据之间的关联性识别精度,还增强了系统对复杂文档的理解能力,使得系统能够从多模态数据中提取更准确、更全面的语义信息,克服了现有技术中单模态处理的局限性。

[0170] 在本发明的技术方案中,基于图结构学习模型对知识图谱的节点权重和边权重进行自适应优化,通过引入梯度下降算法和优化损失函数的计算能够动态调整知识图谱中节点和边的权重分布,优化后的知识图谱能够更精准地表达文本与非文本数据之间的语义关系,相比现有的知识图谱构建技术,本发明不仅能够处理纯文本数据,还可以有效结合图像和图表数据,使构建的知识图谱具有更高的表达能力和精度,确保复杂文档中的关键知识得以全面表示。

[0171] 本发明通过引入改进的BERT模型和自监督学习机制,结合多模态融合技术,显著提高了复杂文档的自动化处理效率,与传统需要大量人工干预的技术不同,本发明能够在无监督或弱监督的情况下通过深度语义分析与实体识别和关系抽取步骤,实现自动化的知识提取和结构化处理,减少了人工操作的复杂度,同时大幅降低了处理多模态文档的时间成本,提高了系统的整体处理效率,解决了现有技术在大规模、多模态文档处理中的效率低下问题。

[0172] 以上所述,仅为本发明较佳的具体实施方式,但本发明的保护范围并不局限于此,任何熟悉本技术领域的技术人员在本发明揭露的技术范围内,根据本发明的技术方案及其发明构思加以等同替换或改变,都应涵盖在本发明的保护范围之内。




图1